

แบบเสนอหัวข้อและโครงร่างการทำโครงการทางวิศวกรรม

ประจำปีการศึกษาที่ 2 ปีการศึกษา 2568

1. หัวข้อโครงร่าง (Thesis Title)

ภาษาไทย (ไทย) การประยุกต์ใช้จมูกอิเล็กทรอนิกส์ร่วมกับการเรียนรู้ของเครื่องในการ
ประเมินปริมาณก๊าซมีเทนในนาข้าว

ภาษาอังกฤษ (English) Application of Electronic Nose Coupled with Machine
Learning for Estimating Methane Emissions in Rice Paddies

2. ชื่อและรหัสนักศึกษา (Student name and code)

นาย ปัญญกุล พงษ์พานิช — รหัส 680631040 วิศวกรรมศาสตรมหาบัณฑิต วิศวกรรม
เกษตร

3. อาจารย์ที่ปรึกษา (Advisor)

ผศ.ดร. ณัฐวุฒิ เนียมสอน ภาควิชาวิศวกรรมเครื่องกล มหาวิทยาลัยเชียงใหม่

4. บทนำ (Introduction)

4.1. ที่มาและความสำคัญ (Overviews)

ข้าวเป็นพืชเศรษฐกิจหลักของประเทศไทย ทั้งในด้านการส่งออกและรายได้ของเกษตรกร ในปี
พ.ศ. 2567 ไทยส่งออกข้าวได้ประมาณ 10 ล้านตัน สร้างรายได้ราว 6.5 พันล้านดอลลาร์สหรัฐ [1, 2,
3] และมีครัวเรือนเกษตรกรทำนาปลูกข้าวกว่า 4.6 ล้านครัวเรือน ครอบคลุมพื้นที่มากกว่า 115,000
ตารางกิโลเมตร [1, 2] แม้สัดส่วนต่อผลิตภัณฑ์มวลรวมภายในประเทศจะไม่สูงเท่าอุตสาหกรรมอื่น ถึง
อย่างนั้นข้าวยังเป็นแหล่งรายได้และมีผลต่อการดำรงชีพของครัวเรือนในชนบทจำนวนมาก ในการ
พัฒนาการเกษตรข้าวจึงไม่ได้จำกัดอยู่แค่การเพิ่มผลผลิตเพียงอย่างเดียว แต่รวมถึงการจัดการ
ผลกระทบต่อสิ่งแวดล้อมที่เกิดจากรูปแบบการปลูกด้วย

การปลูกข้าวในไทยส่วนใหญ่เป็นแบบน้ำขัง ทั้งนาปีและนาปรัง [4] เมื่อมีน้ำขังในนาอย่างต่อเนื่อง
สภาวะดินจะขาดออกซิเจน จุลินทรีย์กลุ่มสร้างก๊าซมีเทน (methanogens) จึงย่อยสลายอินทรีย์วัตถุ
และปล่อยก๊าซมีเทน (CH₄) ออกสู่บรรยากาศ ทั้งทางผิวน้ำและทางรากหรือลำต้นข้าว [4] ก๊าซมีเทน
เป็นก๊าซเรือนกระจกที่มีศักยภาพในการกักเก็บความร้อนสูง นาข้าวจึงเป็นหนึ่งในแหล่งปล่อย CH₄
สำคัญของภาคเกษตร โดยมีรายงานว่าสัดส่วนการปล่อยจากนาข้าวอยู่ในช่วงร้อยละ 12–26 ของก๊าซ
เรือนกระจกจากพื้นที่เกษตร [4] ปริมาณที่ปล่อยจริงยังเปลี่ยนแปลงตามฤดูกาล การจัดการน้ำ พันธุ์

ข้าว และสภาพดิน หากต้องการลดการปล่อยหรือติดตามผลของมาตรการลดก๊าซ จึงต้องอาศัยข้อมูล การวัดที่เชื่อถือได้ในระดับแปลงนา มากกว่าค่าเฉลี่ยระดับภูมิภาค

ปัจจุบันมีหลายวิธีสำหรับการวัดก๊าซมีเทนจากนาข้าว โดยแต่ละวิธีเหมาะกับบริบทการใช้งานที่ ต่างกัน เช่น (1) การใช้ห้องเก็บตัวอย่าง (static chamber) ร่วมกับก๊าซโครมาโทกราฟี (GC) ถือเป็นวิธี อ้างอิงที่ให้ความแม่นยำสูง ทั้งสำหรับการวิเคราะห์ความเข้มข้นในตัวอย่างอากาศและการประมาณ อัตราการปล่อย (flux) ซึ่งวิธีที่ยอมรับกันอย่างกว้างขวาง [6, 7] แต่ต้องใช้แรงงานและต้นทุนมาก การ เก็บข้อมูลทำได้ไม่บ่อย จึงติดตามการเปลี่ยนแปลงตลอดฤดูปลูกได้ยาก [6, 7] (2) เทคนิคสเปกโทรส โคปีและการสังเกตจากดาวเทียม ให้ข้อมูลในระดับภูมิภาคหรือระดับความละเอียดในระดับนี้ แต่มี ต้นทุนสูงและความละเอียดเชิงพื้นที่มักไม่ละเอียดพอถึงระดับรายแปลงนา [8, 22] ทางเลือกที่ต้นทุน ต่ำกว่าคือเซ็นเซอร์ก๊าซและจมูกอิเล็กทรอนิกส์ (electronic nose หรือ eNose) ซึ่งเป็นอาร์เรย์เซ็นเซอร์ หลายตัวที่นำไปใช้ร่วมกับ machine learning (ML) ในการประเมินความเข้มข้นของก๊าซ [5, 12]


แนวทาง eNose ร่วมกับ ML มีศักยภาพสำหรับการประเมินความเข้มข้น CH_4 ในการใช้ ในภาคสนาม โดยเฉพาะเมื่อนำค่าอุณหภูมิ และ ความชื้น รวมเข้าในแบบจำลองเพื่อชดเชยผลกระทบ จากสภาพแวดล้อม [10] งานวิจัยก่อนหน้ายังเน้นการพิสูจน์แนวคิดหรือการทดลองในห้องแล็บ มากกว่าการสร้างแบบจำลอง regression ที่ให้ค่าความเข้มข้น CH_4 (หน่วย ppm) บนฮาร์ดแวร์ที่ นำไปใช้ในแปลงจริงได้ [11, 12] ขณะที่บริบทนาข้าวไทยมีความชื้นสูง การเปลี่ยนแปลงตามฤดูกาล และสภาพแวดล้อมที่ซับซ้อน จึงยังจำเป็นต้องพัฒนาและตรวจสอบแบบจำลองใหม่ภายใต้เงื่อนไขที่ เกี่ยวข้องกับแปลงนา โดยอ้างอิงกับวิธี chamber-GC [6, 7]

ดังนั้นจึงมุ่งพัฒนาเครื่องและแบบจำลอง จากสัญญาณเครื่อง eNose ที่พัฒนาขึ้นและบันทึกค่า อุณหภูมิ และ ความชื้น และเปรียบเทียบความสอดคล้องของค่าความเข้มข้น CH_4 (ppm) ที่ทำนายได้ กับค่าที่ได้จากเครื่อง GC

4.2. สรุปสาระสำคัญจากงานวิจัยที่เกี่ยวข้อง (Literature reviews)


4.2.1 การปล่อยก๊าซมีเทนจากนาข้าวและปัจจัยควบคุม

การปลูกข้าวแบบน้ำขังทำให้นดินอยู่ในสภาวะขาดออกซิเจน (anaerobic) ซึ่งเอื้อต่อการเจริญเติบโตของ จุลินทรีย์กลุ่มสร้างมีเทน (methanogens) ในการย่อยสลายอินทรีย์วัตถุและปล่อยก๊าซมีเทน (CH_4) ออกสู่ บรรยากาศ ทั้งผ่านผิวน้ำ ฟองอากาศ และผ่านท่อลำเลียงอากาศในต้นข้าว [4] ด้วยเหตุนี้ข้าวจึง กลายเป็นหนึ่งในแหล่งปล่อย CH_4 ที่สำคัญ จากการศึกษาพบว่าการปลูกข้าวปล่อย CH_4 คิดเป็นประมาณ ร้อยละ 10–12 ของการปล่อยมีเทนทั่วโลก [13] หรือราวร้อยละ 11 ของการปล่อยมีเทนทั้งหมดที่ระดับ 308×10^{12} g ต่อปี [14] เมื่อพิจารณาว่าประมาณร้อยละ 90 ของข้าวถูกผลิตและบริโภคในทวีปเอเชีย จึงเป็น ภูมิภาคที่มีความสำคัญเชิงยุทธศาสตร์ต่อการลดการปล่อยก๊าซ [13]



รูปที่ 1: กระบวนการเกิดและเส้นทางปล่อย CH_4 ในนาข้าว (Ji et al., *Front. Sustain. Food Syst.*, 2024, FIGURE 1)

ปริมาณการปล่อย CH_4 จากนาข้าวผันแปรตามการจัดการน้ำ, พันธุ์ข้าว, คุณสมบัติดิน และฤดูกาล จากการศึกษาของ Nguyen et al. [4] สรุปไว้ว่าการปล่อย CH_4 และไนตรัสออกไซด์ (N_2O) จากพื้นที่นา ขึ้นอยู่กับรูปแบบการจัดการแปลงปลูกเป็นหลัก ในบรรดาปัจจัยเหล่านี้ การจัดการน้ำ ให้ผลชัดเจนที่สุด จากงานวิเคราะห์ภาพรวมจากการเก็บข้อมูล 47 ที่ พบว่าการจัดการน้ำแบบเปียกสลับแห้ง (alternate wetting and drying, AWD) สามารถลดการปล่อย CH_4 ได้เฉลี่ย ร้อยละ 64.5 ± 12.3 เมื่อเทียบกับการขังน้ำต่อเนื่อง โดยลดได้มากกว่าในพื้นที่เขตร้อน (ร้อยละ 68.2) และในพื้นที่ปลูกลักษณะดินเหนียว (ร้อยละ 71.3) แต่ทำให้ N_2O เพิ่มขึ้นราวร้อยละ 18.7 ส่งผลให้ศักยภาพภาวะโลกร้อนโดยรวม (GWP) ลดลง ประมาณร้อยละ 42.1 [15] ผลในทิศทางเดียวกันนี้โดยเปรียบเทียบจากการวัดด้วยเทคนิค eddy covariance ที่รายงานว่าการจัดการน้ำแบบ AWD ลด CH_4 ได้อย่างมีนัยสำคัญเมื่อเทียบกับการขังน้ำ [16]




รูปที่ 2: อนุกรมเวลาพล็อต CH_4 แบบ half-hourly ภายใต้ AWD เทียบกับ continuous flooding [16]

นอกจากการจัดการน้ำแล้ว ปัจจัยทางดินและชีวภาพก็มีบทบาทเช่นกัน งานวิจัยที่ศึกษาเกี่ยวกับรากของต้นข้าวชี้ว่าการพัฒนารากข้าวและสภาพดินรอบรากส่งผลต่ออัตราการปล่อย CH_4 [17] ขณะที่ปริมาณคาร์บอนที่ใช้ได้ (carbon availability) และค่า pH ของดินเป็นตัวควบคุมสำคัญของการปล่อยตามการเพิ่มขึ้น/ลดลงตามอุณหภูมิเฉลี่ยรายปี [18] ในอีกมิติหนึ่ง Yang et al. [19] ซึ่งวิเคราะห์ภาพรวมจากการเก็บข้อมูลใน 46 ที่ พบว่าประสิทธิภาพของปุ๋ยไนโตรเจนแบบ enhanced-efficiency (EENF) ต่อการลด CH_4 โดยขึ้นกับพันธุ์ข้าวและขั้นตอนการปลูก เช่น การใช้สาร inhibitor ควบคู่ไปด้วย สามารถลด CH_4 ได้ร้อยละ 23.6 ในพันธุ์ไฮบริด เทียบกับเพียง ร้อยละ 8.2 ในพันธุ์อินเบรด และลดได้สูงสุดถึงร้อยละ 40.6 ในรอบที่สอง หลังเกี่ยวข้าว เมื่อขังน้ำเป็นช่วง (intermittent flooding) inhibitor ลด CH_4 ได้ร้อยละ 24.9 ในขณะที่ภายใต้การขังน้ำต่อเนื่องผลลดลงจนไม่มีนัยสำคัญทางสถิติ [19]

4.2.2 วิธีการวัดปริมาณก๊าซมีเทนแบบมาตรฐาน (Static Chamber ร่วมกับ GC)

จากความต้องการข้อมูลระดับแปลงนาข้างต้น การใช้ ห้องเก็บตัวอย่างแบบปิด (static chamber) ร่วมกับ ก๊าซโครมาโทกราฟี (GC) ยังคงเป็น วิธีอ้างอิง (reference method / ground truth) ที่ได้รับการยอมรับกว้างขวางที่สุดสำหรับการวัดฟลักซ์ (flux) ของก๊าซเรือนกระจกจากดินเกษตรกรรม [6] หลักการวัดคือครอบ chamber ลงบนผิวดินหรือผิวน้ำเป็นระยะเวลาหนึ่ง แล้วเก็บตัวอย่างอากาศภายในตามช่วงเวลาเพื่อคำนวณอัตราการสะสมความเข้มข้นของ CH_4 ต่อหน่วยพื้นที่ต่อเวลา (เช่น $\text{mg m}^{-2} \text{h}^{-1}$) ก่อนนำไปวิเคราะห์ด้วย GC ในห้องปฏิบัติการ [6]



รูปที่ 3: ความเข้มข้น CH_4 ใน chamber เทียบกับสัญญาณเซ็นเซอร์และความชื้น (Bastviken et al., *Biogeosciences*, 2020, Fig. 3)

แม้วิธีนี้จะให้ความแม่นยำและความน่าเชื่อถือสูง แต่ข้อจำกัด ต้นทุนสูง, การใช้แรงงานจำนวนมาก และความถี่ในการเก็บตัวอย่างที่ค่อนข้างต่ำ โดยทั่วไปการเก็บตัวอย่างทำได้เพียงไม่กี่ครั้งต่อสัปดาห์ ทำให้เสี่ยงต่อการพลาดจับพลวัตการปล่อยแบบรายวัน หรือปรากฏการณ์การปล่อยก๊าซเป็นฟองอากาศจากดินที่เกิดขึ้นเป็นช่วง ๆ และติดตามการเปลี่ยนแปลงตลอดฤดูปลูกได้ยาก [7]

4.2.3 วิธีการวัดปริมาณก๊าซมีเทนแบบอื่น ๆ

นอกเหนือจาก chamber-GC ยังมีวิธีการวัดและประเมิน CH_4 จากนาข้าวอีกหลายแนวทาง ซึ่งแต่ละแบบมีจุดเด่นและข้อจำกัดที่แตกต่างกันในมิติของความแม่นยำ, ความละเอียดเชิงพื้นที่, ต้นทุน และความเหมาะสมกับการติดตามต่อเนื่อง โดยมีวิธีดังต่อไปนี้


เทคนิคสเปกโทรสโกปี เช่น Tunable Diode Laser Absorption Spectroscopy (TDLAS), Cavity Ring-Down Spectroscopy (CRDS) และ Fourier Transform Infrared Spectroscopy (FTIR) [8] สามารถวัดความเข้มข้น CH_4 ได้ในระดับ ppm ถึง ppb พร้อมการตอบสนองที่รวดเร็ว, ให้ความแม่นยำสูง และเหมาะกับงานในห้องปฏิบัติการหรือสถานีตรวจวัดคงที่ แต่มีต้นทุนที่สูง, ต้องการการตั้งค่าที่ซับซ้อน และไม่สามารถติดตั้งหลายจุดในแปลงนา หรือการติดตามอย่างต่อเนื่องตลอดฤดูปลูก ในทางปฏิบัติ การนำเครื่องมือวิเคราะห์ที่ความแม่นยำสูงใช้ร่วมกับ chamber จึงกลายเป็นทางเลือกที่พยายามลดข้อจำกัดของ GC แบบเก็บ vial จากงานวิจัยของ Vo et al. [21] ได้เปรียบเทียบ laser-based Trace Gas Analyzer (TGA) ทั้งแบบพกพาและแบบ multi-valve กับ manual chamber-GC ในข้าวนาภายใต้ AWD และการขัง

น้ำต่อเนื่องที่ IRRI ผลทดลองพบว่าทั้งสามวิธีให้ค่าฟลักซ์ CH_4 ใกล้เคียงกัน โดย two-way ANOVA แสดงว่าปัจจัยวิธีวัดไม่มีนัยสำคัญ ($p = 0.47$) และไม่พบ interaction กับการจัดการน้ำ ($p = 0.728$) ความต่างสูงสุดระหว่าง GC กับ multi-valve TGA อยู่ที่ $12.62 \text{ mg CH}_4 \text{ m}^{-2} \text{ d}^{-1}$ ซึ่งยังเล็กเมื่อเทียบกับระดับการปล่อยโดยรวม ประมาณร้อยละ 90 ของข้อมูล TGA ได้ R^2 ของความเข้มข้น-เวลาสูงกว่า 0.9 ทั้งที่ครอบ chamber เพียง 4 นาที เทียบกับ 30 นาทีของ GC และระบบ multi-valve สามารถครอบคลุมได้มากกว่า 110 แปลงต่อวัน เทียบกับราว 48 แปลงต่อวันของ manual GC [21] ผลเหล่านี้ชี้ว่า TGA ให้ผลเทียบเคียง GC ได้ดี แต่ยังมีต้นทุนลงทุนสูง สำหรับแปลงนาทั่วไปที่ต้องการทางเลือกต้นทุนต่ำ

การสังเกตจากระยะไกล (remote sensing) ทั้งจากดาวเทียมและอากาศยานไร้คนขับ (UAV) ครอบคลุมพื้นที่กว้างได้ แต่ความละเอียดเชิงพื้นที่ยังไม่ละเอียดพอในระดับรายแปลงนา Xu et al. [22] นำเสนอการประยุกต์ AI/ML เข้ากับข้อมูล remote sensing เพื่อประเมิน CH_4 จากนาข้าว ซึ่งเหมาะกับการประเมินระดับภูมิภาคมากกว่าการติดตามแบบเรียลไทม์ในแปลงเดี่ยว Vo et al. [21] ยังชี้ว่าเกณฑ์ตรวจจับของดาวเทียมปัจจุบัน (ราว $100\text{--}10,000 \text{ kg CH}_4 \text{ h}^{-1}$) ยังห่างจากอัตราปล่อยพื้นหลังของนาข้าวในเอเชียตะวันออกเฉียงใต้ (ประมาณ $0.05 \text{ kg CH}_4 \text{ ha}^{-1} \text{ h}^{-1}$) หลายระดับ ทำให้การประมาณจากระยะไกลยังต้องพึ่งการวัดภาคพื้นดินเป็นข้อมูลอ้างอิง


เซ็นเซอร์ก๊าซต้นทุนต่ำ Rajasekar และ Selvi [5] พัฒนาระบบ chamber อัตโนมัติพร้อมหน่วยประมาณค่าก๊าซด้วยเซ็นเซอร์ MQ4 และ TGS2611 เพื่อติดตาม CH_4 , N_2O และ CO_2 จากนาข้าวใน 2 ฤดูปลูก ที่ Thanjavur ประเทศอินเดีย โดยเปรียบเทียบการจัดการน้ำแบบ continuous flooding (CF), intermittent flooding (IF) และ controlled intermittent flooding (CIF) เมื่อเทียบกับ CF และ IF ขณะที่ N_2O ในฤดูแล้งสูงกว่าฤดูฝนราวสามเท่า การแปลงค่าเป็น ppm ใช้สูตรผู้ผลิต $\text{ppm} = (\text{Rs}/\text{R0})^{-2.95} \times 1000$ แทนแบบจำลองการเรียนรู้จากอาเรย์เซ็นเซอร์หลายตัว [5]

จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) เป็นระบบที่เลียนแบบการรับกลิ่นของมนุษย์ ประกอบด้วยอาเรย์ของเซ็นเซอร์ก๊าซที่มีความเลือกจำเพาะบางส่วน (partially selective) ระบบเก็บสัญญาณ และซอฟต์แวร์วิเคราะห์รูปแบบ [24] เมื่อก๊าซเป้าหมายสัมผัสพื้นผิวเซ็นเซอร์ โดยเฉพาะเซ็นเซอร์ชนิดโลหะออกไซด์ (metal oxide semiconductor, MOS) ความต้านทานของวัสดุจะเปลี่ยนแปลงตามความเข้มข้นของก๊าซ สัญญาณรวมจากเซ็นเซอร์หลายตัวจึงกลายเป็นเวกเตอร์หลายมิติ (smell print) ที่นำไปจำแนกชนิดหรือประเมินความเข้มข้นได้ จากการศึกษาของ Ye et al. [24] สรุปว่าการนำการเรียนรู้ของเครื่องมาใช้ทำให้ eNose สามารถทำงานได้ทั้งเชิงคุณภาพ (จำแนกชนิดก๊าซ) และเชิงปริมาณ (ประเมินความเข้มข้น) ได้



รูปที่ 4: สถาปัตยกรรมระบบเซ็นเซอร์มีเทนต้นทุนต่ำร่วมกับ Raspberry Pi (Kiplimo et al., Atmosphere, 2024, Fig. 1; [10], [28])

งานวิจัยของ Domènech-Gil et al. [10] ซึ่งพัฒนา eNose ต้นทุนต่ำสำหรับการติดตาม CH_4 ในบรรยากาศ โดยใช้เซ็นเซอร์ MOS หลายตัว (Figaro TGS2611) ควบคู่กับเซ็นเซอร์วัดอุณหภูมิ ความชื้น และความดัน (BME680) แล้วใช้แบบจำลอง Partial Least Squares Regression (PLSR) ชดเชยผลกระทบจากสภาพแวดล้อมในห้องปฏิบัติการ ระบบให้ $R^2 > 0.9$ และ $\text{RMSE} < 100$ ppb ในช่วง 0–9 ppm CH_4 ส่วนในสภาพภาคสนามสามารถวัดได้ถึงระดับความเข้มข้นบรรยากาศ (ราว 2 ppm) โดยให้ค่าความคลาดเคลื่อน RMSE ต่ำสุดถึง 33 ppb และค่า R^2 สูงสุดถึง 0.91 [10] ผลลัพธ์นี้แสดงถึงความเป็นไปได้ของแนวทาง eNose+ML สำหรับการตรวจจับและประเมินปริมาณ CH_4 แต่ในการใช้งานจริงช่วงความเข้มข้นยังต่างจากนาข้าวที่มีความชื้นสูงและสภาพแวดล้อมซับซ้อน จึงไม่สามารถนำแบบจำลองมาใช้โดยตรง โดยข้อจำกัดที่ปรากฏซ้ำในวรรณกรรมคือ cross-sensitivity ต่อความชื้น อุณหภูมิ และก๊าซรบกวนอื่น เช่น Ahmad et al. [12] ทดลองศักยภาพของเซ็นเซอร์ MOS สำหรับ precision agriculture และเน้นว่าความไวต่อสารอินทรีย์ระเหยง่าย (VOC) และการเปลี่ยนแปลงของสภาพแวดล้อมยังเป็นข้อจำกัดหลักที่ต้องชดเชยด้วยแบบจำลองหลายตัวแปร งานสนับสนุนอื่น ๆ [25],[26]




รูปที่ 5: ผลสอบเทียบ eNose+PLSR กับค่าอ้างอิงในภาคสนาม [10]

การชดเชย cross-sensitivity ของ MOS ด้วยเซ็นเซอร์สภาพแวดล้อม (T/H) ร่วมกับ ML เพื่อชดเชยผลของสภาพแวดล้อมต่างๆที่มีผลต่อความแม่นยำ [10], [12], [27] ยังไม่พบงานที่รวมทั้งสามองค์ประกอบ eNose แบบอาร์เรย์ MOS, ML regression ให้ค่า ppm ต่อเนื่อง และในบริบทของนาข้าว จึงมุ่งพัฒนาระบบ eNose ที่ชดเชยผลของสิ่งแวดล้อม และทำนายปริมาณ CH_4 ได้

SENSORS 2022, 22, 1111

3 of 11



รูปที่ 6: ระบบ chamber อัตโนมัติพร้อมเซ็นเซอร์สำหรับนาข้าว (ดัดแปลงจาก Rajasekar และ Selvi [5],

Fig. 3)

4.3. วัตถุประสงค์ของการศึกษา (Research Objectives)

- พัฒนาและประเมินระบบ eNose-ML ที่ให้ค่าความเข้มข้น CH_4 เป็นหน่วย ppm โดยใช้ static chamber ร่วมกับ GC เป็นหลักอ้างอิงในการฝึกและตรวจสอบแบบจำลอง
- ทดสอบประสิทธิภาพของแบบจำลองที่พัฒนาขึ้น โดยเปรียบเทียบค่าความเข้มข้นที่ทำนายจากสัญญาณ eNose กับค่าที่วัดได้จากเครื่อง GC ภายใต้เงื่อนไขที่ควบคุมได้ และระบุข้อจำกัดของระบบอย่างชัดเจนเมื่อรายงานผล

4.4. ขอบเขตของการศึกษา (Research scopes and limitations)

- ขอบเขตการเก็บข้อมูลฝึกและทดสอบครอบคลุมความเข้มข้น CH_4 เป้าหมายที่ 5, 10, 15, 20, 30, 40, 50, 60, 70, 80, 90 และ 100 ppm
- การทดสอบครอบคลุมอุณหภูมิของสภาพแวดล้อมสามระดับ ได้แก่ 30, 40 และ 50 องศาเซลเซียส

4.5. ประโยชน์ที่คาดว่าจะได้รับ (Research Contribution)

- ได้ระบบปัญญาอิเล็กทรอนิกส์ต้นทุนต่ำที่พกพาและทำงานบนแพลตฟอร์ม Raspberry Pi ได้
- ได้แบบจำลองถดถอยที่ประมาณความเข้มข้น CH_4 เป็น ppm ในช่วงความเข้มข้นและอุณหภูมิที่ฝึกไว้ พร้อมตัวชี้วัดความคลาดเคลื่อนเทียบกับ GC


5. หลักการและทฤษฎีที่เกี่ยวข้อง

5.1. ภาพรวมระบบวัดและการประมาณความเข้มข้น CH_4

ระบบใช้จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) บน Raspberry Pi ประมาณความเข้มข้น CH_4 เป็นหน่วยส่วนในล้านส่วน (parts per million, ppm) โดยเทียบกับ Gas Chromatograph (GC) ฮาร์ดแวร์ประกอบด้วยเซ็นเซอร์โลหะออกไซด์ (metal oxide semiconductor, MOS) ชนิด Figaro TGS2612 สี่ช่อง (มีและไม่มีตัวกรองอย่างละสอง) เซ็นเซอร์สภาพแวดล้อม BME280 และตัวแปลงอนาล็อกเป็นดิจิทัล ADS1263 ลำดับการไหลถูกควบคุมด้วยวาล์วโซลินอยด์ บั๊ม และฮีตเตอร์ เพื่อสร้างช่วง Baseline และ Measure จากนั้นสกัดลักษณะเด่น ได้แก่ การเปลี่ยนแปลงแรงดันสัมพัทธ์ (ΔV) ความชัน อัตราส่วน และค่าเฉลี่ยอุณหภูมิ ความชื้น ความดัน แล้วส่งเข้าแบบจำลองถดถอยเชิงเส้น (Linear Regression) ที่ฝึกบนอุปกรณ์และโหลดขึ้น Raspberry Pi

กรอบทฤษฎี: eNose-ML ปริมาณความเข้มข้น CH₄ (ppm) เทียบกับ GC

ค่าประมาณเสริม — ไม่ทดแทนการรายงานผลลักษณะมาตรฐาน



รูปที่ 7: กรอบทฤษฎีระบบ eNose-ML สำหรับปริมาณความเข้มข้น CH₄ (ppm) และเปรียบเทียบกับ GC

5.2. ก๊าซมีเทนในระบบนาข้าว

การปลูกข้าวแบบน้ำขังทำให้ดินใต้ผิวน้ำอยู่ในสภาวะไร้ออกซิเจน (anaerobic) จุลินทรีย์กลุ่มสร้างมีเทน (methanogens) จึงย่อยสลายอินทรีย์วัตถุและผลิต CH₄ ซึ่งปล่อยสู่บรรยากาศได้สามทางหลัก ได้แก่ การแพร่ผ่านผิวน้ำ การปล่อยเป็นฟอง (ebullition) และการลำเลียงผ่านระบบอากาศในต้นข้าว [4], [13] อัตราการผลิตและการปล่อยถูกกำกับด้วยการจัดการน้ำ พันธุ์ข้าว สภาพดินรอบราก (rhizosphere) ปริมาณคาร์บอนที่ใช้ได้ และค่า pH ของดิน [4], [17], [18], [19] ความเข้มข้น CH₄ ในผิวน้ำมีพลวัตตามฤดูกาล ระยะเจริญเติบโต และช่วงเวลาในวัน การเก็บตัวอย่างห่างช่วงจึงอาจพลาดพลวัตรายวันหรือการเกิด ebullition [7], [13]

5.2.1 ความเข้มข้นและฟลักซ์

ในงานวัดก๊าซจากพื้นผิวน้ำมักใช้สองปริมาณ ได้แก่ ความเข้มข้น ซึ่งเป็นสัดส่วนของโมเลกุล CH₄ ในอากาศตัวอย่าง (ppm หรือ ppb) และฟลักซ์ ซึ่งเป็นอัตราการปล่อยมวลต่อหน่วยพื้นที่ต่อเวลา เช่น mg CH₄ m⁻² h⁻¹ หากในช่วงเวลาสั้น ๆ หลังครอบห้องปิด ความเข้มข้นเพิ่มขึ้นเกือบเชิงเส้นตามเวลา ฟลักซ์โดยประมาณได้จากความชันของความเข้มข้นต่อเวลา คูณด้วยอัตราส่วนปริมาตรต่อพื้นที่ฐาน และตัวแปลงตามกฎของแก๊สในอุดมคติ

$$\rho_{CH_4} = c \cdot \frac{P}{R T} \quad (5.1)$$

$$C(t) \approx C_0 + \frac{dC}{dt} t \quad (5.2)$$

$$F = \frac{dC}{dt} \cdot \frac{V}{A} \cdot \frac{P}{R T} \quad (5.3)$$

เมื่อ

ρ_{CH_4} คือ ความหนาแน่นมวลของ CH₄ (หน่วย: kg/m³)

c คือ ความเข้มข้นในหน่วยสัดส่วนโมล หรือค่าที่แปลงจาก ppm แล้ว (—)

P คือ ความดัน (หน่วย: Pa)

T คือ อุณหภูมิสัมบูรณ์ (หน่วย: K)

M คือ มวลโมเลกุลของ CH₄ (หน่วย: kg/mol)

R คือ ค่าคงที่แก๊ส (หน่วย: J/(mol·K))

C(t) คือ ความเข้มข้นในหัว chamber ตามเวลา

C₀ คือ ความเข้มข้นเริ่มต้นเมื่อครอบห้อง

dC/dt คือ ความชันความเข้มข้นต่อเวลาในช่วงที่เลือก

F คือ ฟลักซ์มวลของ CH₄ (หน่วย: เช่น mg·m⁻²·h⁻¹)

V คือ ปริมาตรหัว chamber (หน่วย: m³)

A คือ พื้นฐานที่ครอบ (หน่วย: m²)


5.3. หลักการวัดด้วย static chamber และ GC

Static closed chamber คือการครอบห้องปิดบนผิวดินหรือผิวน้ำในช่วงสั้น ๆ เพื่อให้อากาศในห้องสะสมก๊าซ หากอัตราการปล่อยคงที่พอสมควร ความเข้มข้น CH₄ จะเพิ่มขึ้นเกือบเชิงเส้นตามเวลา [6] การคำนวณฟลักซ์ใช้ความชันของความเข้มข้น คูณกับปริมาตรและพื้นที่ฐาน โดยต้องชี้ลขอบของ chamber และผสมอากาศในห้อง แล้วบันทึกอุณหภูมิ-ความดัน และเลือกช่วงถดถอยที่เหมาะสม [6] ในทางปฏิบัติ การครอบแบบมือร่วมกับ GC มักใช้เวลาประมาณ 20–30 นาทีต่อจุด จึงจำกัดจำนวนจุดต่อวันด้วยแรงงาน [7], [21]

Gas Chromatograph (GC) แยกส่วนประกอบของตัวอย่างก๊าซแล้ววัดสัญญาณของแต่ละชนิดตามลำดับเวลา จากนั้นแปลงเป็นความเข้มข้นโดยเทียบกับก๊าซมาตรฐาน [6] หลักการทำงานคือฉีดตัวอย่างเข้ากระแสก๊าซพา (carrier gas เช่น N₂, He หรือ Ar) ให้ไหลผ่าน packed column เช่น Haysep Q หรือ Molsieve ซึ่งทำให้ก๊าซต่างชนิดเคลื่อนที่ด้วยความเร็วต่างกัน [6] สำหรับ CH₄ มักใช้ flame ionization detector (FID) เมื่อก๊าซผ่านเปลวไฟจะเกิดอิเล็กตรอนอิสระและสร้างกระแสไฟฟ้าตามสัดส่วนปริมาณไฮโดรคาร์บอน แล้วใช้พื้นที่พิคเทียบเส้นสอบเทียบเพื่อได้ค่าความเข้มข้น [6], [7] ส่วน thermal conductivity detector (TCD) ในระบบวัดก๊าซเรือนกระจกหลายชนิดมักใช้วัด CO₂ [6]

Static closed chamber: จากความชันความเข้มข้นสุฟลักซ์ และการอ้างอิง GC

$$F = (dC/dt) \cdot (V/A) \cdot (PM)/(RT)$$



รูปที่ 8: หลักการ static closed chamber ความชันความเข้มข้น ฟลักซ์ และการอ้างอิงด้วย GC

5.4. หลักการจมูกอิเล็กทรอนิกส์และเซ็นเซอร์ MOS

จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) จำลองแนวคิดการดมกลิ่นของจมูกคน โดยใช้เซ็นเซอร์ก๊าซหลายตัวร่วมกัน แทนที่จะพึ่งเซ็นเซอร์ตัวเดียวที่จำเพาะต่อก๊าซชนิดใดชนิดหนึ่ง เซ็นเซอร์แต่ละตัวมักตอบสนองต่อก๊าซได้หลายชนิดในระดับต่างกัน หรือมีความเลือกจำเพาะบางส่วน (partially selective) ดังนั้นเมื่อมีก๊าซเป้าหมาย เช่น CH_4 เข้ามา แต่ละช่องจะให้สัญญาณไม่เหมือนกัน เมื่อนำสัญญาณทุกช่องมารวมกันจะได้รูปแบบหลายมิติ หรือลายพิมพ์กลิ่น (smell print) จากนั้นใช้ซอฟต์แวร์วิเคราะห์รูปแบบและการเรียนรู้ของเครื่องเพื่อจำแนกชนิดก๊าซหรือประมาณความเข้มข้น [24]

เซ็นเซอร์ชนิดโลหะออกไซด์ (metal oxide semiconductor, MOS) ที่เลือกใช้งานโดยให้ความร้อนชั้นวัสดุโลหะออกไซด์ เมื่อโมเลกุลก๊าซรีดิวซ์ เช่น CH_4 ทำปฏิกิริยาที่พื้นผิว ความต้านทานไฟฟ้าของชั้นวัสดุจะเปลี่ยนไป ระบบจึงอ่านค่าเป็นแรงดันผ่านวงจรแบ่งแรงดัน [12], [26]

$$V_{out} = V_c \frac{R_L}{R_S + R_L} \quad (5.4)$$

$$R_S = R_L \left(\frac{V_c}{V_{out}} - 1 \right) \quad (5.5)$$

เมื่อ

V_{out} คือ แรงดันขาออกของวงจรแบ่งแรงดัน (V)


V_c คือ แรงดันจ่ายวงจร (V)

R_L คือ ความต้านทานโหลดคงที่ (Ω)

R_S คือ ความต้านทานของชั้นเซ็นเซอร์ MOS (Ω)

จุดเด่นของ MOS คือต้นทุนต่ำ ขนาดเล็ก และอ่านสัญญาณต่อเนื่องได้ ข้อจำกัดคือการตอบสนองมักไม่เป็นเส้นตรงตลอดช่วงความเข้มข้นกว้าง และสัญญาณยังเปลี่ยนแปลงตามความชื้น อุณหภูมิ ความดัน ก๊าซอื่นที่ปนอยู่ รวมทั้งสารอินทรีย์ระเหยง่าย (volatile organic compounds, VOC) [10], [12], [26] ข้อมูลผู้ผลิตตระกูล Figaro ยังแสดงว่าแรงดันขาออกขึ้นกับทั้งความเข้มข้นมีเทน อุณหภูมิ และความชื้น ดังนั้นช่วงความเข้มข้นต่ำมากอาจใช้ความสัมพันธ์เชิงเส้นได้เฉพาะช่วงแคบ [28] การจัดอาเรย์ให้มีทั้งช่องที่มีตัวกรองและไม่มีตัวกรองช่วยให้ลายพิมพ์สัญญาณหลากหลายขึ้น ซึ่งสอดคล้องกับแนวคิด eNose [24]

เซ็นเซอร์ MOS และวงจรแบ่งแรงดันสู่ ADS1263



Cross-sensitivity ต่อ T / RH แล้วชดเชยด้วย BME280 + แบบจำลอง ML

รูปที่ 9: หลักการเซ็นเซอร์ MOS และวงจรแบ่งแรงดันสู่การอ่านด้วย ADS1263

5.5. การไหลของก๊าซและการสกัดลักษณะเด่น

เพื่อให้เปรียบเทียบสัญญาณเซ็นเซอร์ระหว่างรอบวัดได้ ระบบต้องทำให้การไหลของอากาศและสภาวะก่อนวัดใกล้เคียงกันทุกครั้ง จึงควบคุมวาล์ว ปัมป์ และฮีตเตอร์ตามลำดับอัตโนมัติ แต่ละรอบแบ่งเป็นสองช่วงหลัก ได้แก่

ช่วงแรก Baseline คือช่วงอ้างอิงขณะไหลอากาศสะอาดหรือสภาวะอ้างอิง เพื่อดูว่าเซ็นเซอร์อยู่หนึ่งที่ระดับใดก่อนเจอก๊าซตัวอย่าง และ ช่วงสอง Measure คือช่วงนำอากาศตัวอย่างเข้าห้องวัด เพื่อดูว่าสัญญาณเปลี่ยนไปอย่างไรเมื่อมี CH_4 หรือก๊าซที่เกี่ยวข้อง การวัดแบบนี้ช่วยให้การเปลี่ยนแปลงของสัญญาณเทียบกับเบสไลน์ แทนการใช้แรงดันดิบเพียงอย่างเดียว จึงลดผลจากการเลื่อนเบสไลน์ระหว่างวันหรือระหว่างเงื่อนไขอุณหภูมิ [12], [26], [28]

อุณหภูมิห้องทดสอบถูกควบคุมด้วยฮีตเตอร์ เพราะอุณหภูมิมีผลทั้งต่อปฏิกิริยาที่พื้นผิวเซ็นเซอร์และต่อความชื้นในอากาศตัวอย่าง [12], [26], [28] สัญญาณที่อ่านจาก ADS1263 มีสัญญาณรบกวนความถี่สูง จึงต้องผ่านตัวกรองความถี่ต่ำ (low-pass filter) และค่าเฉลี่ยเคลื่อนที่ (smoothing average) ก่อนนำไปหาค่าต่ำสุด ค่าสูงสุด และค่าเฉลี่ยในช่วงวิเคราะห์ หน้าต่างเวลาของ Baseline และ Measure ต้องตรงกับที่ใช้ตอนฝึกโมเดล หากเปลี่ยนหน้าต่างโดยไม่ฝึกใหม่ การทำนายจะคลาดเคลื่อน

5.5.1 นิยาม ΔV และความชัน

ให้ $V_{bl,i}$ เป็นค่าเฉลี่ยแรงดันของช่องเซ็นเซอร์ที่ i ในช่วง Baseline และให้ $V_{min,i}$ กับ $V_{max,i}$ เป็นค่าต่ำสุดและค่าสูงสุดในช่วง Measure ลักษณะเด่นหลักคำนวณจากผลต่างของสัญญาณในช่วง Measure เทียบกับเบสไลน์ โดยเลือกใช้ค่าสูงสุดหรือค่าต่ำสุดในช่วง Measure เป็น $V_{ext,i}$ ตามทิศทางสัญญาณ

$$\Delta V_i = V_{ext,i} - V_{bl,i} \quad (5.6)$$

$$slope_i = \frac{V_{max,i} - V_{min,i}}{t_{max,i} - t_{min,i}} \quad (5.7)$$

$$ratio_i = \frac{V_{max,i} - V_{bl,i}}{V_{bl,i}} \quad (5.8)$$

เมื่อ

$V_{bl,i}$ คือ ค่าเฉลี่ยแรงดันของช่องเซ็นเซอร์ที่ i ในช่วง Baseline (หน่วย: V)

$V_{ext,i}$ คือ ค่าสูงสุดหรือค่าต่ำสุดในช่วง Measure ตามทิศทางสัญญาณของช่อง i (หน่วย: V)


ΔV_i คือ ผลต่างแรงดันสัมพัทธ์ของช่อง i (หน่วย: V)

$slope_i$ คือ ความชันสัญญาณในช่วง Measure จาก $(V_{max,i} - V_{min,i}) / (t_{max,i} - t_{min,i})$ (หน่วย: V/s)

$ratio_i$ คือ อัตราส่วนการตอบสนองแบบนอร์มอลไลซ์ $(V_{max,i} - V_{bl,i}) / V_{bl,i}$ (—)

ในระบบจริง แต่ละช่องอาจตอบสนองคนละทิศทาง บางช่องสัญญาณลงจากเบสไลน์จึงใช้ $\Delta V = V_{min,i} - V_{bl,i}$ บางช่องสัญญาณขึ้นจึงใช้ $V_{max,i} - V_{bl,i}$ ส่วน $dV_{max,i} = V_{max,i} - V_{bl,i}$ ใช้กับทุกช่อง และ $ratio_i$ ในสมการ (5.8) นอร์มอลไลซ์ $dV_{max,i}$ ด้วยค่า Baseline ระบบยังใช้ค่าเฉลี่ยอุณหภูมิและความชื้นในช่วง Baseline และ Measure และค่าเฉลี่ยความดันในช่วง Measure จาก BME280 เป็นตัวแปรร่วม

หน้าต่าง Baseline-Measure และการสกัดลักษณะเด่น (ΔV , slope, ratio)



รูปที่ 10: หน้าต่าง Baseline-Measure และการสกัดลักษณะเด่น ΔV ความชื้น และอัตราส่วน

5.6. การเรียนรู้ของเครื่องสำหรับการประมาณความเข้มข้น

การเรียนรู้ของเครื่องใช้สร้างความสัมพันธ์ระหว่างสัญญาณที่ระบบวัดได้กับความเข้มข้น CH_4 อ้างอิงจาก GC ข้อมูลนำเข้าคือเวกเตอร์จากลักษณะเด่นจากแต่ละเซ็นเซอร์ก๊าซและ BME280 ตามหัวข้อ 5.5 ส่วนผลลัพธ์คือค่าความเข้มข้นต่อเนื่องในหน่วย ppm งานลักษณะนี้เรียกว่าการถดถอย (regression) ซึ่งต่างจากการจำแนกประเภทที่ให้คำตอบเป็นกลุ่ม เช่น มีหรือไม่มีมีเทน แบบจำลองหลักที่เลือกใช้คือสมการการถดถอยเชิงเส้น (Linear Regression)

หลักการฝึกเป็นการเรียนรู้แบบมีผู้สอน (supervised learning) โดยแต่ละรอบวัดประกอบด้วยคู่ข้อมูล (x , y) เมื่อ x คือเวกเตอร์ลักษณะเด่น และ y คือความเข้มข้นอ้างอิงจาก GC ก่อนฝึกจะเลือกเฉพาะลักษณะเด่นที่ใช้กับโมเดลและปรับมาตรฐานของตัวแปร (standardization) เพื่อให้ตัวแปรซึ่งมีหน่วยและช่วงค่าต่างกันอยู่ในสเกลที่เปรียบเทียบกันได้ จากนั้น Linear Regression จะหาค่าสัมประสิทธิ์ที่ทำให้ผลรวมกำลังสองของความคลาดเคลื่อนระหว่างค่าทำนายกับค่าอ้างอิงต่ำที่สุด หรือหลักการ least squares

$$\hat{y} = \beta_0 + \sum_j \beta_j x_j \quad (5.9)$$

เมื่อ

$\hat{y}$ คือ ความเข้มข้นที่แบบจำลองประมาณได้ (หน่วย: ppm)

β_0 คือ ค่าคงที่ของสมการ (—)

β_j คือ สัมประสิทธิ์หรือน้ำหนักของลักษณะเด่นที่ j (—)

x_j คือ ค่าลักษณะเด่นแต่ละตัว (หน่วยตามชนิดตัวแปร) ในขั้นทำนาย (inference)

ระบบสกัดลักษณะเด่นจากรอบวัดใหม่ด้วยนิยามและหน้าต่างเวลาเดียวกับตอนฝึก จัดเรียงตัวแปรตามชุดที่โมเดลกำหนด ปรับสเกลด้วยค่าที่บันทึกจากการฝึก แล้วส่งเข้าโมเดลเพื่อคำนวณ $\hat{y}$ กระบวนการบน Raspberry Pi จึงเป็นการใช้โมเดลที่ฝึกไว้แล้ว ไม่ใช่การฝึกโมเดลใหม่ทุกครั้งที่วัด

Linear Regression มีข้อดีคือตีความสัมประสิทธิ์ได้ คำนวณรวดเร็ว และเหมาะกับคอมพิวเตอร์ขนาดเล็ก วิธีนี้ตั้งอยู่บนสมมติฐานว่าความสัมพันธ์ระหว่างลักษณะเด่นกับความเข้มข้นอธิบายได้ด้วยผลรวมเชิงเส้น หากตัวแปรจำนวนมากมีความสัมพันธ์กัน งาน eNose สำหรับ CH_4 บางชุดใช้ Partial Least Squares Regression (PLSR) เพื่อจัดการสหสัมพันธ์ระหว่างตัวแปร [10] ขณะที่การสอบเทียบเซ็นเซอร์ Figaro แสดงว่าการใส่อุณหภูมิและความชื้นช่วยลดความคลาดเคลื่อนในบางช่วงความเข้มข้น [27], [28] จึงเลือก Linear Regression ภายในช่วงฝึกประมาณ 5–100 ppm และตรวจสอบผลกับ GC โดยค่าที่ได้เป็นค่าประมาณจากแบบจำลองเทียบกับผลวัดจากเครื่องมืออ้างอิง หากนำไปใช้นอกช่วงความเข้มข้นหรือสภาวะที่ฝึก ต้องเก็บข้อมูลอ้างอิงและฝึกตรวจสอบโมเดลใหม่

5.6.1 ตัวชี้วัดความคลาดเคลื่อน

หลังฝึกแบบจำลองแล้ว ประเมินความใกล้เคียงระหว่างค่าที่ทำนายกับค่าจาก GC ด้วยตัวชี้วัดสามตัว ได้แก่ ค่ารากที่สองของความคลาดเคลื่อนกำลังสองเฉลี่ย (root mean square error, RMSE) ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (mean absolute error, MAE) ซึ่งมีหน่วยเดียวกับ ppm และสัมประสิทธิ์การตัดสินใจ (R^2) ซึ่งสะท้อนว่าแบบจำลองอธิบายความแปรปรวนของค่าอ้างอิงได้มากน้อยเพียงใด

$$RMSE = \sqrt{\frac{1}{n} \sum_{k=1}^n (y_k - \hat{y}_k)^2} \quad (5.10)$$

$$MAE = \frac{1}{n} \sum_{k=1}^n |y_k - \hat{y}_k| \quad (5.11)$$

$$R^2 = 1 - \frac{\sum_k (y_k - \hat{y}_k)^2}{\sum_k (y_k - \bar{y})^2} \quad (5.12)$$

เมื่อ

y_k คือ ค่าอ้างอิงจาก GC ของตัวอย่างที่ k (หน่วย: ppm)

$\hat{y}_k$ คือ ค่าที่แบบจำลองทำนาย (หน่วย: ppm)

$\bar{y}$ คือ ค่าเฉลี่ยของ y_k (หน่วย: ppm)

n คือ จำนวนตัวอย่างในชุดประเมิน (—)

RMSE และ MAE ยิ่งต่ำยิ่งดี ส่วน R^2 โดยทั่วไปอยู่ในช่วงประมาณ 0–1 และยิ่งใกล้ 1


ยิ่งสอดคล้องกับข้อมูลอ้างอิง การประเมินต้องแยกชุดฝึกกับชุดทดสอบ หรือใช้การตรวจสอบข้ามภายใต้ช่วงความเข้มข้นและสภาวะที่กำหนด [6], [7]

6. วิธีการดำเนินงานวิจัย

การพัฒนาและตรวจสอบระบบจมูกอิเล็กทรอนิกส์ (electronic nose, eNose) ที่ประมาณความเข้มข้นก๊าซมีเทน (CH_4) เป็นหน่วย ppm จากสัญญาณอาเรย์เซ็นเซอร์โลหะออกไซด์ร่วมกับตัวแปรสภาพแวดล้อมแล้วเปรียบเทียบกับค่าอ้างอิงจาก Gas Chromatograph (GC) ภายใต้สภาวะควบคุมในห้องปฏิบัติการ ขั้นตอนหลักมีสี่ขั้น ได้แก่ (1) ติดตั้งและปรับระบบ eNose (2) เก็บชุดข้อมูลคู่กับ GC (3) สกัดลักษณะเด่นและฝึกแบบจำลองถดถอยนอกเครื่อง แล้วโหลดขึ้น Raspberry Pi และ (4) ประเมินความสอดคล้องด้วยตัวชี้วัดความคลาดเคลื่อนตามบทที่ 5

6.1. เครื่องมือและระบบ eNose

ระบบ eNose ใช้ Raspberry Pi 5 เป็นหน่วยประมวลผลกลาง อ่านสัญญาณเซ็นเซอร์ Figaro TGS2612 จำนวน 4 ช่อง (มีตัวกรอง 2 ช่อง และไม่มีตัวกรอง 2 ช่อง) ผ่านโมดูล ADS1263 (SPI) และวัดอุณหภูมิ ความชื้นสัมพัทธ์ และความดันด้วย BME280 (I2C) การไหลของก๊าซควบคุมด้วยวาล์วโซลินอยด์ปั๊ม และพัดลมผ่านรีเลย์ และใช้ฮีตเตอร์อุ่นเซ็นเซอร์ให้เข้าสู่อุณหภูมิทำงาน ซอฟต์แวร์ควบคุมทำงานผ่าน GUI โหมด Auto (Op1–Op7) สำหรับกำหนดระยะเวลาแต่ละขั้น บันทึกสัญญาณ และแสดงค่าประมาณ ppm หลังจบรอบวัด แผนผังฮาร์ดแวร์แสดงดังรูปที่ 11



รูปที่ 11: แผนผังระบบ eNose แสดงเส้นทางก๊าซ การอ่าน TGS2612/BME280 ผ่าน Raspberry Pi 5 และการส่งออกไฟล์กับตัวอย่างคู่ GC

6.2. การออกแบบทดลอง

การทดลองหลักคือหนึ่งรอบวัด Auto ภายใต้เงื่อนไข (ความเข้มข้นเป้าหมาย, อุณหภูมิ) เพื่อสร้างชุดข้อมูลที่มีป้ายกำกับจาก GC พารามิเตอร์ของแผนทดลองกำหนดดังนี้

- ความเข้มข้น CH_4 เป้าหมาย: 5, 10, 15, 20, 30, 40, 50, 60, 70, 80, 90 และ 100 ppm
- อุณหภูมิของสภาพแวดล้อม: 30, 40 และ 50 °C
- การทำซ้ำ: อย่างน้อย 3 รอบ

- สภาพแวดล้อมของชุดข้อมูลหลัก: สภาพควบคุมในห้องปฏิบัติการ

6.3. โปรโตคอลเก็บข้อมูล Op1–Op7 และหน้าต่างวิเคราะห์


แต่ละรอบวัดใช้โหมด Auto ตามลำดับ Op1–Op7 โดยระยะเวลาตั้งในหน้า Settings และต้องบันทึกค่าที่ใช้จริงทุกชุดทดลอง สำหรับชุดข้อมูลที่สอดคล้องกับหน้าต่างวิเคราะห์ของโมเดลปัจจุบัน ขึ้น Baseline ต้องยาวพอให้ครอบคลุมประมาณ 250–300 วินาทีหลังเริ่มบันทึกที่ Op2 (ตัวอย่างที่ใช้งานประมาณ 300 วินาที) และขึ้น Measure ใช้ประมาณ 60 วินาทีเพื่อครอบคลุมหน้าต่างวิเคราะห์ประมาณ 305–365 วินาทีหลังเริ่มบันทึก ลำดับการทำงานมีดังนี้

- 1.) Op1 Heating: ช้อนเซ็นเซอร์จนเซ็นเซอร์เข้าสู่อุณหภูมิทำงานโดยยังไม่บันทึกข้อมูล
- 2.) Op2 Baseline: เริ่มบันทึก และอ้างอิงสัญญาณพื้นฐานให้ยาวพอครอบคลุมหน้าต่างวิเคราะห์ Baseline
- 3.) Op3 Vacuum และ Op4 Mix air: เตรียมเส้นทางก๊าซและจัดอากาศตามลำดับระบบ
- 4.) Op5 Measure: นำอากาศตัวอย่างเข้าห้องวัด (ประมาณ 60 วินาที)

ให้ครอบคลุมหน้าต่างวิเคราะห์ Measure

- 5.) Op6 Valve return และ Op7 Recovery: คำนวณทางไหล คำนวณระบบแล้วประมวลผลค่าประมาณ ppm

ในแต่ละรอบที่บันทึก ให้เก็บสัญญาณจาก ADS1263 ค่าจาก BME280 ควบคู่กัน สำหรับการตรวจสอบความเข้มข้นของตัวอย่าง ให้สุ่มตัวอย่างอากาศนำไปวิเคราะห์ด้วย GC และใช้ค่าความเข้มข้นจาก GC เป็นป้ายกำกับ [6] แผนภาพเวลาและหน้าต่างวิเคราะห์แสดงดังรูปที่ 12




รูปที่ 12: ลำดับ Auto Op1–Op7 เริ่มบันทึกที่ Op2 และหน้าต่างวิเคราะห์ Baseline (~250–300 s) กับ Measure (~305–365 s)

6.4. การสร้างแบบจำลองและประเมินผล

จากไฟล์สัญญาณที่บันทึกในแต่ละรอบ จะกรองสัญญาณรบกวน และสกัด feature extraction ตามนิยามในบทที่ 5 ได้แก่ ΔV , ความชัน และ Normalization

ดังสมการ (5.6)–(5.8) พร้อมค่าเฉลี่ยอุณหภูมิ ความชื้นสัมพัทธ์ และความดันจาก BME280 ใน หน้าต่างเวลาเดียวกัน หน้าต่าง Baseline–Measure ที่ใช้ตอนวิเคราะห์ต้องตรงกับที่ใช้ตอนฝึกโมเดล และ feature สุดท้ายที่ป้อนเข้าโมเดลคือชุดย่อยที่เลือกไว้ตอนฝึกโมเดลหลักที่โหลดขึ้น Raspberry Pi โดยมี pipeline สองขั้น ได้แก่ (1)StandardScaler สำหรับปรับสเกลของ feature ให้เทียบกันได้ และ (2)Linear Regression ตามลำดับ สำหรับประมาณความเข้มข้น CH₄ เป็น ppm ตัวแปรตาม (y) โดยการฝึกทำนอกเครื่อง และไม่ฝึกใหม่บน Raspberry Pi ขณะใช้งาน การทำนายใช้รูปแบบดังสมการ (5.9) ผ่านสคริปต์ predict_methane.py แผนภาพ pipeline แสดงดังรูปที่ 13

- 1.) แบ่งข้อมูลออกเป็นสองส่วนก่อนเริ่มเลือก feature และฝึกโมเดล ส่วนแรกประมาณร้อยละ 70–80 ใช้เป็นชุดฝึก ส่วนที่สองประมาณร้อยละ 20–30 กันไว้เป็นชุดทดสอบสุดท้าย (holdout) โดยไม่นำไปเลือก feature และไม่นำไปฝึก ในชุดฝึก จะใช้การตรวจสอบไขว้แบบจัดกลุ่ม (GroupKFold) ตาม session หรือ batch เพื่อไม่ให้รอบที่วัดภายใต้เงื่อนไขเดียวกันหลุดไปอยู่ทั้งชุดฝึกและชุดประเมินพร้อมกัน สัดส่วนปรับได้ตามจำนวนรอบจริงที่ได้
- 2.) นำโมเดลไปทำนายค่า ppm บนชุดทดสอบ แล้วเทียบกับค่าจาก GC ด้วยตัวชี้วัด RMSE, MAE และ R² ตามสมการ (5.10)–(5.12) รายงานทั้งค่าภาพรวมของทั้งชุด และค่าแยกตามช่วงความเข้มข้นกับอุณหภูมิ สภาพแวดล้อม พร้อมแสดงกราฟค่าทำนายเทียบกับค่า GC และระบุจำนวนรอบที่ติดทิ้งเพราะไม่ผ่านเกณฑ์คุณภาพข้อมูล หากผลในบางช่วงยังคลาดเคลื่อนสูง อาจเปรียบเทียบโมเดลทางเลือกเป็นการวิเคราะห์เสริม โดยไม่เปลี่ยนฮาร์ดแวร์ [10], [28]



รูปที่ 13: Pipeline จากสกัด feature การแยก holdout/Grouped CV การฝึก StandardScaler–Linear Regression และการโหลดขึ้น Raspberry Pi

7. สถานที่ในการดำเนินโครงการ (Location)
8. แผนการดำเนินงาน (Project timeline)
9. งบประมาณ (Budget)

เอกสารอ้างอิง (References)

- [1] C. Sowcharoensuk, "Industry Outlook 2026-2028: Rice Industry," Krungsri Research, 2026.
[Online]. Available: <https://www.krungsri.com/th/research/industry/industry-outlook/agriculture/rice/io/io-rice-2026-2028>
- [2] T. Nation, "Thai farm incomes face pressure from global rice market shifts," *The Nation*, 2026.
- [3] Thairath, "Thai Rice Exports in 2025 Surpass Targets Efforts Accelerate in 2026 to Maintain and Expand Markets," *Thairath*, 2026.
- [4] H. Nguyen et al., "Carbon Footprint Reduction from Closing Rice Yield Gaps," in *Carbon Footprint of Rice Production*, 2023, pp. 149–176.
- [5] P. Rajasekar and J. A. V. Selvi, "Sensing and Analysis of Greenhouse Gas Emissions from Rice Fields to the Near Field Atmosphere," *Sensors*, vol. 22, no. 11, p. 4141, 2022.
- [6] M. Zaman et al., "Methodology for measuring greenhouse gas emissions from agricultural soils using non-isotopic techniques," in *Measuring Emission of Agricultural Greenhouse Gases and Developing Mitigation Options Using Nuclear and Related Techniques*, Springer, 2021, pp. 11–108.
- [7] N. J. Mumu et al., "Methodological progress in the measurement of agricultural greenhouse gases," *Carbon Management*, vol. 15, no. 1, p. 2366527, 2024.
- [8] L. Tyagi et al., "Environmental impacts and recent advancements in the sensing of methane: a review," *Environ. Technol. Rev.*, vol. 14, no. 1, pp. 191–212, 2025.
- [9] M. S. Borhan and M. M. Khanaum, "Sensors and methods for measuring greenhouse gas emissions from different components of livestock production facilities," *J. Geosci. Environ. Prot.*, vol. 10, no. 12, pp. 242–272, 2022.
- [10] G. Domènech-Gil et al., "Electronic nose for improved environmental methane monitoring," *Environ. Sci. Technol.*, vol. 58, no. 1, pp. 352–361, 2023.
- [11] S. Baruah and D. H. Mazumder, "A Review on Application of Machine Learning Techniques Coupled With E-Nose in Healthcare Agriculture and Allied Domains," *IEEE Access*, 2025.
- [12] A. Ahmad et al., "The Promise of Low-Cost Metal-Oxide Semiconductor Gas Sensors for Precision Agriculture," *Adv. Sensor Res.*, 2026.
- [13] H. Zhou et al., "Paddy rice methane emissions, controlling factors, and mitigation potentials across Monsoon Asia," *Sci. Total Environ.*, vol. 935, p. 173441, 2024, doi: 10.1016/j.scitotenv.2024.173441.

- [14] T. D. Xuan, T. T. N. Minh, R. Rayee, N. Dong, and N. X. Chien, "Advances in mitigating methane emissions from rice cultivation: past, present, and future strategies," *Environ. Sci. Pollut. Res.*, 2025, doi: 10.1007/s11356-025-36776-8.
- [15] A. Rafy, M. Hannan, M. Mohammed, and N. Khan, "Meta-Analysis of Alternate Wetting and Drying (AWD) Irrigation Effects on Methane and Nitrous Oxide Emissions Across Different Climates and Soil Types," *Eur. J. Ecol. Biol. Agric.*, vol. 2, no. 5, pp. 181-200, 2025, doi: 10.59324/ejeba.2025.2(5).13.
- [16] S. S. Anapalli, S. R. Pinnamaneni, K. N. Reddy, P. Wagle, and A. J. Ashworth, "Eddy covariance assessment of alternate wetting and drying floodwater management on rice methane emissions," *Heliyon*, vol. 9, no. 4, p. e14696, 2023, doi: 10.1016/j.heliyon.2023.e14696.
- [17] S. Guan, Z. Qi, S. Li, S. Du, and D. Xu, "Effects of rice root development and rhizosphere soil on methane emission in paddy fields," *Plants*, vol. 13, no. 22, p. 3223, 2024, doi: 10.3390/plants13223223.
- [18] D. Yusong et al., "Methane emissions from rice paddies are regulated by carbon availability and soil pH along a mean annual temperature gradient," *Sci. Rep.*, vol. 16, p. 14129, 2026, doi: 10.1038/s41598-026-43940-8.
- [19] T. Yang, M. Wang, X. Wang, C. Xu, F. Fang, and F. Li, "Product type, rice variety, and agronomic measures determined the efficacy of enhanced-efficiency nitrogen fertilizer on the CH₄ emission and rice yields in paddy fields: A meta-analysis," *Agronomy*, vol. 12, no. 10, p. 2240, 2022, doi: 10.3390/agronomy12102240.
- [20] Q. Hu et al., "Global methane emissions from rice paddies: CH₄MOD model development and application," *iScience*, vol. 27, no. 11, p. 111237, 2024, doi: 10.1016/j.isci.2024.111237.
- [21] T. B. T. Vo et al., "Measurement approaches for greenhouse gas emissions from rice II: advanced technology for accelerating throughput," *Front. Agron.*, vol. 7, p. 1693620, 2026, doi: 10.3389/fagro.2025.1693620.
- [22] Y. Xu, A. Yazdinejad, H. Wang, and J. D. Kong, "From detection to decision: A systematic literature review of AI and machine learning evolution in methane modelling," *SSRN*, 2025, doi: 10.2139/ssrn.5218753.
- [23] Q. Zhang et al., "Machine learning-driven method for in-situ high-frequency CH₄ measurement in paddy fields based on water-soil-air factors," *J. Environ. Manage.*, vol. 393, p. 127132, 2025, doi: 10.1016/j.jenvman.2025.127132.

- [24] Z. Ye, Y. Liu, and Q. Li, "Recent progress in smart electronic nose technologies enabled with machine learning methods," *Sensors*, vol. 21, no. 22, p. 7620, 2021, doi: 10.3390/s21227620.
- [25] J. Yin et al., "Rapid identification method for CH₄/CO/CH₄-CO gas mixtures based on electronic nose," *Sensors*, vol. 23, no. 6, p. 2975, 2023, doi: 10.3390/s23062975.
- [26] L. Fu, S. You, G. Li, X. Li, and Z. Fan, "Application of semiconductor metal oxide in chemiresistive methane gas sensor: Recent developments and future perspectives," *Molecules*, vol. 28, no. 18, p. 6710, 2023, doi: 10.3390/molecules28186710.
- [27] B. Andrews, A. Chakrabarti, M. Dauphin, and A. Speck, "Application of machine learning for calibrating gas sensors for methane emissions monitoring," *Sensors*, vol. 23, no. 24, p. 9898, 2023, doi: 10.3390/s23249898.
- [28] H. L. Mitchell, S. J. Cox, and H. G. Lewis, "Calibration of a low-cost methane sensor using machine learning," *Sensors*, vol. 24, no. 4, p. 1066, 2024, doi: 10.3390/s24041066.