แบบเสนอหัวข้อและโครงร่างการทำโครงงานทางวิศวกรรม

ประจำภาคการศึกษาที่ 2 ปีการศึกษา 2568

1. หัวข้อโครงร่าง (Thesis Title)

ภาษาไทย (ไทย) การประยุกต์ใช้จมูกอิเล็กทรอนิกส์ในการประเมินความเข้มข้นก๊าซมีเทนในนาข้าว

ภาษาอังกฤษ (English) Application of Electronic Nose for Evaluating Methane Gas Concentration in Rice Paddies

2. ชื่อและรหัสนักศึกษา (Student name and code)

นาย ปัญจกุล พงษ์พานิช — รหัส 680631040 วิศวกรรมศาสตรมหาบัณฑิต วิศวกรรมเกษตร

3. อาจารย์ที่ปรึกษา (Advisor)

ผศ.ดร. ณัฐวุฒิ เนียมสอน ภาควิชาวิศวกรรมเครื่องกล มหาวิทยาลัยเชียงใหม่

4. บทนำ (Introduction)

4.1. ที่มาและความสำคัญ (Overviews)

ข้าวเป็นพืชเศรษฐกิจหลักของประเทศไทย ทั้งในด้านการส่งออกและรายได้ของเกษตรกร ในปี พ.ศ. 2567 ไทยส่งออกข้าวได้ประมาณ 10 ล้านตัน สร้างรายได้ราว 6.5 พันล้านดอลลาร์สหรัฐ [1, 2, 3] และมีครัวเรือนเกษตรกรทำนาปลูกข้าวกว่า 4.6 ล้านครัวเรือน ครอบคลุมพื้นที่มากกว่า 115,000 ตารางกิโลเมตร [1, 2] แม้สัดส่วนต่อผลิตภัณฑ์มวลรวมภายในประเทศจะไม่สูงเท่าอุตสาหกรรมอื่น ถึงอย่างนั้นข้าวยังเป็นแหล่งรายได้และมีผลต่อการดำรงชีพของครัวเรือนในชนบทจำนวนมาก ในการพัฒนาการเกษตรข้าวจึงไม่ได้จำกัดอยู่ที่การเพิ่มผลผลิตเพียงอย่างเดียว แต่รวมถึงการจัดการผลกระทบต่อสิ่งแวดล้อมที่เกิดจากรูปแบบการปลูกด้วย

การปลูกข้าวในไทยส่วนใหญ่เป็นแบบน้ำขัง ทั้งนาปีและนาปรัง [4] เมื่อมีน้ำขังในนาอย่างต่อเนื่อง สภาวะดินจะขาดออกซิเจน จุลินทรีย์กลุ่มสร้างก๊าซมีเทน (methanogens) จึงย่อยสลายอินทรียวัตถุและปล่อยก๊าซมีเทน ($CH_4$) ออกสู่บรรยากาศ ทั้งทางผิวน้ำและทางรากหรือลำต้นข้าว [4] ก๊าซมีเทนเป็นก๊าซเรือนกระจกที่มีศักยภาพในการกักเก็บความร้อนสูง นาข้าวจึงเป็นหนึ่งในแหล่งปล่อย $CH_4$ สำคัญของภาคเกษตร โดยมีรายงานว่าสัดส่วนการปล่อยจากนาข้าวอยู่ในช่วงร้อยละ 12–26 ของก๊าซเรือนกระจกจากพื้นที่เกษตร [4] ปริมาณที่ปล่อยจริงยังเปลี่ยนแปลงตามฤดูกาล การจัดการน้ำ พันธุ์

ข้าว และสภาพดิน หากต้องการลดการปล่อยหรือติดตามผลของมาตรการลดก๊าซ จึงต้องอาศัยข้อมูลการวัดที่เชื่อถือได้ในระดับแปลงนา มากกว่าค่าเฉลี่ยระดับภูมิภาค

ปัจจุบันมีหลายวิธีสำหรับการวัดก๊าซมีเทนจากนาข้าว โดยแต่ละวิธีเหมาะกับบริบทการใช้งานที่ต่างกัน ตัวอย่างเช่น การใช้ห้องเก็บตัวอย่าง (static chamber) ร่วมกับก๊าซโครมาโทกราฟี (GC) ถือเป็นวิธีอ้างอิงที่ให้ความแม่นยำสูง ทั้งสำหรับการวิเคราะห์ความเข้มข้นในตัวอย่างอากาศและการประมาณอัตราการปล่อย (flux) ซึ่งวิธีที่ยอมรับกันอย่างกว้างขวาง [6, 7] แต่ต้องใช้แรงงานและต้นทุนมาก การเก็บข้อมูลทำได้ไม่บ่อย จึงติดตามการเปลี่ยนแปลงตลอดฤดูปลูกได้ยาก [6, 7] อีกวิธีหนึ่งได้แก่ เทคนิคสเปกโทรสโกปีและการสังเกตจากดาวเทียม ซึ่งให้ข้อมูลในระดับภูมิภาคหรือระดับความละเอียดในระดับนึง แต่มีต้นทุนสูงและความละเอียดเชิงพื้นที่มักไม่ระเอียดพอถึงระดับรายแปลงนา [8, 22] อีกหนึ่งทางเลือกที่ต้นทุนต่ำกว่าคือเซ็นเซอร์ก๊าซและจมูกอิเล็กทรอนิกส์ (gas sensor and electronic nose) ซึ่งเป็นการใช้เซ็นเซอร์ก๊าซใช้ร่วมกับ machine learning ในการประเมินความเข้มข้นของก๊าซ [5, 12]

แนวทาง (electronic nose, e-nose) ร่วมกับ ML มีศักยภาพสำหรับการประเมินความเข้มข้น $CH_4$ ในการใช้ในภาคสนาม โดยเฉพาะเมื่อนำค่าอุณหภูมิ และ ความชื้น รวมเข้าในแบบจำลองเพื่อชดเชยผลกระทบจากสภาพแวดล้อม [10] งานวิจัยก่อนหน้าจะเน้นการพิสูจน์แนวคิดหรือการทดลองในห้องแล็บ มากกว่าการประยุกต์ใช้แบบจำลอง ที่ให้ค่าความเข้มข้น $CH_4$ (หน่วย ppm) บนฮาร์ดแวร์ที่นำไปใช้ในแปลงจริงได้ [11, 12] และเนื่องจากข้าวไทยมีอุณหภูมิและความชื้นสูง และมีการเปลี่ยนแปลงตามฤดูกาล และสภาพแวดล้อมที่ซับซ้อน จึงยังต้องมีการพัฒนาและตรวจสอบแบบจำลองใหม่ภายใต้เงื่อนไขที่เกี่ยวข้องกับแปลงนา โดยอ้างอิงกับวิธี chamber–GC [6, 7]

วิทยานิพนธ์นี้จึงมีวัตถุประสงค์เพื่อพัฒนาและประยุกต์ใช้จมูกเล็กทรอนิกส์ในการประเมินความเข้มข้นของก๊าซมีเทนในแปลงนาข้าว

## 4.2. สรุปสาระสำคัญจากงานวิจัยที่เกี่ยวข้อง (Literature reviews)

### 4.2.1 การปล่อยก๊าซมีเทนจากนาข้าวและปัจจัยควบคุม

การปลูกข้าวแบบน้ำขังทำให้ดินอยู่ในสภาวะขาดออกซิเจน (anaerobic) ซึ่งเอื้อต่อการเจริญเติบโตของจุลินทรีย์กลุ่มสร้างมีเทน (methanogens) ในการย่อยสลายอินทรียวัตถุและปล่อยก๊าซมีเทน ($CH_4$) ออกสู่บรรยากาศ ทั้งผ่านผิวน้ำ ฟองอากาศ และผ่านท่อลำเลียงอากาศในต้นข้าว [4] ด้วยเหตุนี้นาข้าวจึงกลายเป็นหนึ่งในแหล่งปล่อย $CH_4$ ที่สำคัญ จากการศึกษาพบว่าการปลูกข้าวปล่อย $CH_4$ คิดเป็นประมาณร้อยละ 10–12 ของการปล่อยมีเทนทั่วโลก [13] หรือราวร้อยละ 11 ของการปล่อยมีเทนทั้งหมดที่ระดับ $308*10^{12}$ g ต่อปี [14] เมื่อพิจารณาว่าประมาณร้อยละ 90 ของข้าวถูกผลิตและบริโภคในทวีปเอเชีย จึงเป็นภูมิภาคที่มีความสำคัญเชิงยุทธศาสตร์ต่อการลดการปล่อยก๊าซ [13]

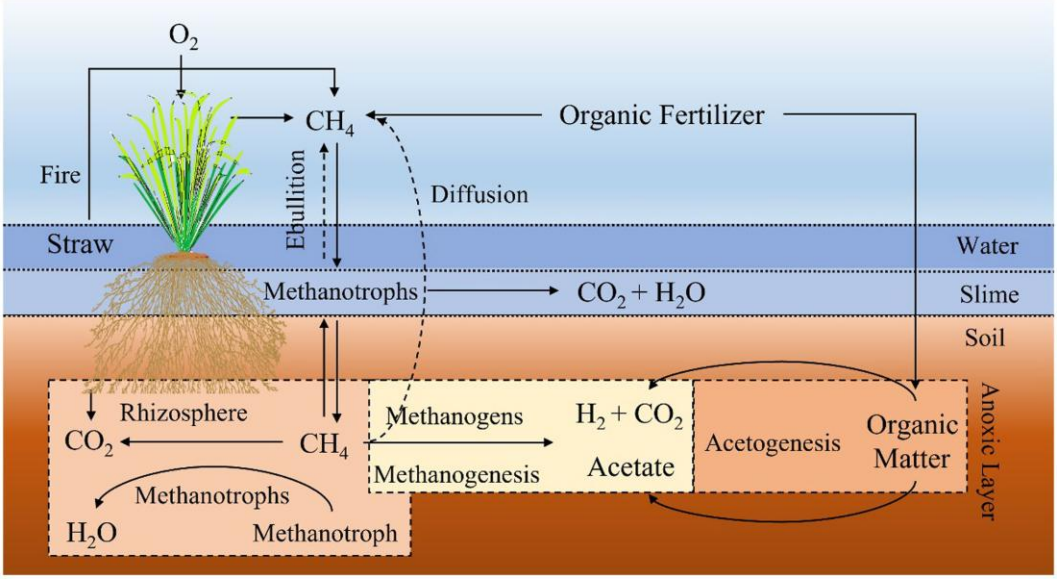


*รูปที่ 1: กระบวนการเกิดและเส้นทางปล่อย $CH_4$ ในนาข้าว (Ji et al., Front. Sustain. Food Syst., 2024, FIGURE 1)*

ปริมาณการปล่อย $CH_4$ จากนาข้าวผันแปรตามการจัดการน้ำ, พันธุ์ข้าว, คุณสมบัติดิน และฤดูกาล จากการศึกษาของ Nguyen et al. [4] สรุปไว้ว่าการปล่อย $CH_4$ และไนตรัสออกไซด์ ($N_2O$) จากพื้นที่นาขึ้นอยู่กับรูปแบบการจัดการแปลงปลูกเป็นหลัก ในบรรดาปัจจัยเหล่านี้ การจัดการน้ำ ให้ผลชัดเจนที่สุด จากงานวิเคราะห์ภาพรวมจากจากการเก็บข้อมูล 47 ที่ พบว่าการจัดการน้ำแบบเปียกสลับแห้ง (alternate wetting and drying, AWD) สามารถลดการปล่อย $CH_4$ ได้เฉลี่ย ร้อยละ 64.5 ± 12.3 เมื่อเทียบกับการขังน้ำต่อเนื่อง โดยลดได้มากกว่าในพื้นที่เขตร้อน (ร้อยละ 68.2) และในพื้นที่ปลูกลักษณะดินเหนียว (ร้อยละ 71.3) แต่ทำให้ $N_2O$ เพิ่มขึ้นราวร้อยละ 18.7 ส่งผลให้ศักยภาพภาวะโลกร้อนโดยรวม (GWP) ลดลงประมาณร้อยละ 42.1 [15] ผลในทิศทางเดียวกันนี้โดยเปรียบเทียบจากการวัดด้วยเทคนิค eddy covariance ที่รายงานว่า AWD ลด $CH_4$ ได้อย่างมีนัยสำคัญเมื่อเทียบกับการขังน้ำ [16]

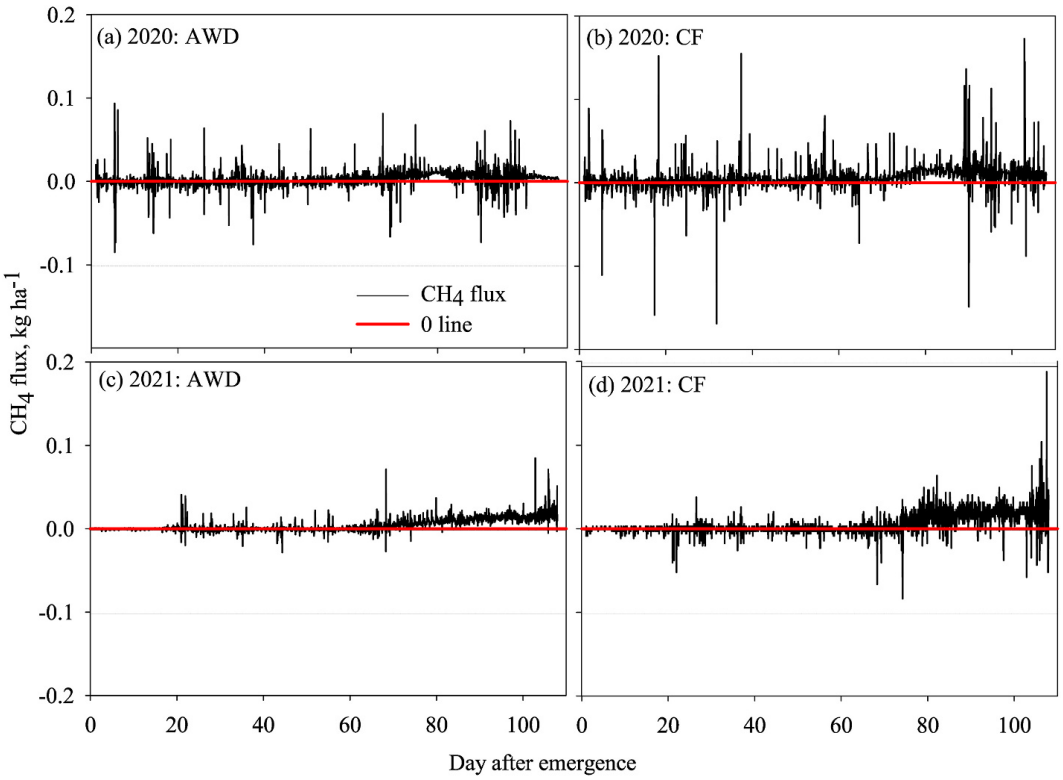


*รูปที่ 2: อนุกรมเวลาฟลักซ์ $CH_4$ แบบ half-hourly ภายใต้ AWD เทียบกับ continuous flooding [16]*

นอกจากการจัดการน้ำแล้ว ปัจจัยทางดินและชีวภาพก็มีบทบาทเช่นกัน งานวิจัยที่ศึกษาเกี่ยวกับรากของต้นข้าวชี้ว่าการพัฒนารากข้าวและสภาพดินรอบรากส่งผลต่ออัตราการปล่อย $CH_4$ [17] ขณะที่ปริมาณคาร์บอนที่ใช้ได้ (carbon availability) และค่า pH ของดินเป็นตัวควบคุมสำคัญของการปล่อยตามการเพิ่มขึ้น/ลดลงตามอุณหภูมิเฉลี่ยรายปี [18] ในอีกมิติหนึ่ง Yang et al. [19] ซึ่งวิเคราะห์ภาพรวมจากการเก็บข้อมูลใน 46 ที่ พบว่าประสิทธิผลของปุ๋ยไนโตรเจนแบบ enhanced-efficiency (EENF) ต่อการลด $CH_4$ โดยขึ้นกับพันธุ์ข้าวและขั้นตอนการปลูก เช่น การใช้สาร inhibitor ควบคู่ไปด้วย สามารถลด $CH_4$ ได้ร้อยละ 23.6 ในพันธุ์ไฮบริด เทียบกับเพียง ร้อยละ 8.2 ในพันธุ์อินเบรด และลดได้สูงสุดถึงร้อยละ 40.6 ในรอบที่สอง หลังเกี่ยวข้าว เมื่อขังน้ำเป็นช่วง (intermittent flooding) inhibitor ลด $CH_4$ ได้ร้อยละ 24.9 ในขณะที่ภายใต้การขังน้ำต่อเนื่องผลลดลงจนไม่มีนัยสำคัญทางสถิติ [19]

### 4.2.2 วิธีการวัดปริมาณก๊าซมีเทนแบบมาตรฐาน (Static Chamber ร่วมกับ GC)

จากความต้องการข้อมูลระดับแปลงนาข้างต้น การใช้ ห้องเก็บตัวอย่างแบบปิด (static chamber) ร่วมกับ ก๊าซโครมาโทกราฟี (GC) ยังคงเป็น วิธีอ้างอิง (reference method / ground truth) ที่ได้รับการยอมรับกว้างขวางที่สุดสำหรับการวัดฟลักซ์ (flux) ของก๊าซเรือนกระจกจากดินเกษตรกรรม [6] หลักการวัดคือครอบ chamber ลงบนผิวดินหรือผิวน้ำเป็นระยะเวลาหนึ่ง แล้วเก็บตัวอย่างอากาศภายในตามช่วงเวลาเพื่อคำนวณอัตราการสะสมความเข้มข้นของ $CH_4$ ต่อหน่วยพื้นที่ต่อเวลา (เช่น mg $m^{-2}$ $h^{-1}$) ก่อนนำไปวิเคราะห์ด้วย GC ในห้องปฏิบัติการ [6]

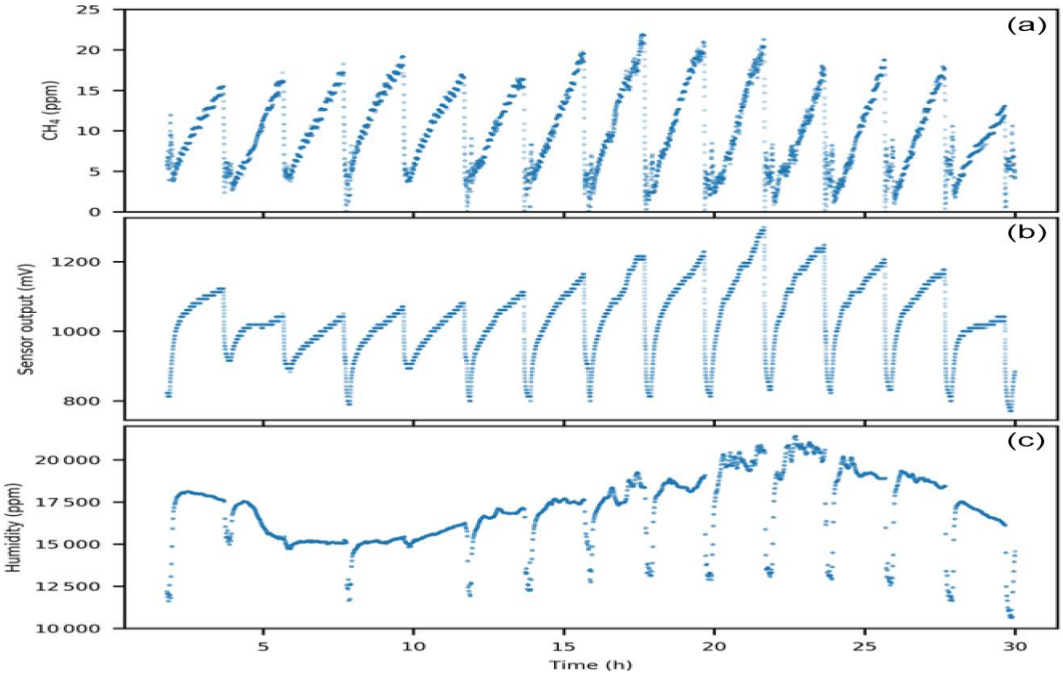


*รูปที่ 3: ความเข้มข้น $CH_4$ ใน chamber เทียบกับสัญญาณเซ็นเซอร์และความชื้น (Bastviken et al., Biogeosciences, 2020, Fig. 3)*

แม้วิธีนี้จะให้ความแม่นยำและความน่าเชื่อถือสูง แต่ข้อจำกัด ต้นทุนสูง, การใช้แรงงานจำนวนมาก และความถี่ในการเก็บตัวอย่างที่ค่อนข้างต่ำ โดยทั่วไปการเก็บตัวอย่างทำได้เพียงไม่กี่ครั้งต่อสัปดาห์ ทำให้เสี่ยงต่อการพลาดจับพลวัตการปล่อยแบบรายวัน หรือปรากฏการณ์การปล่อยก๊าซเป็นฟองอากาศจากดินที่เกิดขึ้นเป็นช่วง ๆ และติดตามการเปลี่ยนแปลงตลอดฤดูปลูกได้ยาก [7]

4.2.3 วิธีการวัดปริมาณก๊าซมีเทนแบบอื่น ๆ

นอกเหนือจาก chamber–GC ยังมีวิธีการวัดและประเมิน $CH_4$ จากนาข้าวอีกหลายแนวทาง ซึ่งแต่ละแบบมีจุดเด่นและข้อจำกัดที่แตกต่างกันในมิติของความแม่นยำ, ความละเอียดเชิงพื้นที่, ต้นทุน และความเหมาะสมกับการติดตามต่อเนื่อง โดยมีวิธีดังต่อไปนี้

เทคนิคสเปกโทรสโกปี เช่น Tunable Diode Laser Absorption Spectroscopy (TDLAS), Cavity Ring-Down Spectroscopy (CRDS) และ Fourier Transform Infrared Spectroscopy (FTIR) [8] สามารถวัดความเข้มข้น $CH_4$ ได้ในระดับ ppm ถึง ppb พร้อมการตอบสนองที่รวดเร็ว, ให้ความแม่นยำสูง และเหมาะกับงานในห้องปฏิบัติการหรือสถานีตรวจวัดคงที่ แต่มีต้นทุนที่สูง, ต้องการการตั้งค่าที่ซับซ้อน และไม่สามารถติดตั้งหลายจุดในแปลงนา หรือการติดตามอย่างต่อเนื่องตลอดฤดูปลูก ในทางปฏิบัติ การนำเครื่องมือวิเคราะห์ที่ความแม่นยำสูงใช้ร่วมกับ chamber จึงกลายเป็นทางเลือกที่พยายามลดข้อจำกัดของ GC แบบเก็บ vial จากงานวิจัยของ Vo et al. [21] ได้เปรียบเทียบ laser-based Trace Gas Analyzer (TGA) ทั้งแบบพกพาและแบบ multi-valve กับ manual chamber–GC ในข้าวนาภายใต้ AWD และการขัง

น้ำต่อเนื่องที่ IRRI ผลทดลองพบว่าทั้งสามวิธีให้ค่าฟลักซ์ $CH_4$ ใกล้เคียงกัน โดย two-way ANOVA แสดงว่าปัจจัยวิธีวัดไม่มีนัยสำคัญ ($p = 0.47$) และไม่พบ interaction กับการจัดการน้ำ ($p = 0.728$) ความต่างสูงสุดระหว่าง GC กับ multi-valve TGA อยู่ที่ 12.62 mg $CH_4$ $m^{-2}$ $d^{-1}$ ซึ่งยังเล็กเมื่อเทียบกับระดับการปล่อยโดยรวม ประมาณร้อยละ 90 ของข้อมูล TGA ได้ $R^2$ ของความเข้มข้น–เวลาสูงกว่า 0.9 ทั้งที่ครอบ chamber เพียง 4 นาที เทียบกับ 30 นาทีของ GC และระบบ multi-valve สามารถครอบคลุมได้มากกว่า 110 แปลงต่อวัน เทียบกับราว 48 แปลงต่อวันของ manual GC [21] ผลเหล่านี้ชี้ว่า TGA ให้ผลเทียบเคียง GC ได้ดี แต่ยังมีต้นทุนลงทุนสูง สำหรับแปลงนาทั่วไปที่ต้องการทางเลือกต้นทุนต่ำ

การสังเกตจากระยะไกล (remote sensing) ทั้งจากดาวเทียมและอากาศยานไร้คนขับ (UAV) ครอบคลุมพื้นที่กว้างได้ แต่ความละเอียดเชิงพื้นที่ยังไม่ละเอียดพอในระดับรายแปลงนา Xu et al. [22] นำเสนอการประยุกต์ AI/ML เข้ากับข้อมูล remote sensing เพื่อประเมิน $CH_4$ จากนาข้าว ซึ่งเหมาะกับการประเมินระดับภูมิภาคมากกว่าการติดตามแบบเรียลไทม์ในแปลงเดียว Vo et al. [21] ยังชี้ว่าเกณฑ์ตรวจจับของดาวเทียมปัจจุบัน (ราว 100–10,000 kg $CH_4$ $h^{-1}$) ยังห่างจากอัตราปล่อยพื้นหลังของนาข้าวในเอเชียตะวันออกเฉียงใต้ (ประมาณ 0.05 kg $CH_4$ $ha^{-1}$ $h^{-1}$) หลายระดับ ทำให้การประมาณจากระยะไกลยังต้องพึ่งการวัดภาคพื้นดินเป็นข้อมูลอ้างอิง

เซ็นเซอร์ก๊าซต้นทุนต่ำ Rajasekar และ Selvi [5] พัฒนาระบบ chamber อัตโนมัติพร้อมหน่วยประมาณค่าก๊าซด้วยเซ็นเซอร์ MQ4 และ TGS2611 เพื่อติดตาม $CH_4$, $N_2O$ และ $CO_2$ จากนาข้าวใน 2 ฤดูปลูก ที่ Thanjavur ประเทศอินเดีย โดยเปรียบเทียบการจัดการน้ำแบบ continuous flooding (CF), intermittent flooding (IF) และ controlled intermittent flooding (CIF) เมื่อเทียบกับ CF และ IF ขณะที่ $N_2O$ ในฤดูแล้งสูงกว่าฤดูฝนราวสามเท่า การแปลงค่าเป็น ppm ใช้สูตรผู้ผลิต ppm = (Rs/R0)^—2.95 × 1000 แทนแบบจำลองการเรียนรู้จากอาเรย์เซ็นเซอร์หลายตัว [5]

จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) เป็นระบบที่เลียนแบบการรับกลิ่นของมนุษย์ ประกอบด้วยอาเรย์ของเซ็นเซอร์ก๊าซที่มีความเลือกจำเพาะบางส่วน (partially selective) ระบบเก็บสัญญาณ และซอฟต์แวร์วิเคราะห์รูปแบบ [24] เมื่อก๊าซเป้าหมายสัมผัสพื้นผิวเซ็นเซอร์ โดยเฉพาะเซ็นเซอร์ชนิดโลหะออกไซด์ (metal oxide semiconductor, MOS) ความต้านทานของวัสดุจะเปลี่ยนแปลงตามความเข้มข้นของก๊าซ สัญญาณรวมจากเซ็นเซอร์หลายตัวจึงกลายเป็นเวกเตอร์หลายมิติ (smell print) ที่นำไปจำแนกชนิดหรือประเมินความเข้มข้นได้ จากการศึกษาของ Ye et al. [24] สรุปว่าการนำการเรียนรู้ของเครื่องมาใช้ทำให้ eNose สามารถทำงานได้ทั้งเชิงคุณภาพ (จำแนกชนิดก๊าซ) และเชิงปริมาณ (ประเมินความเข้มข้น)ได้

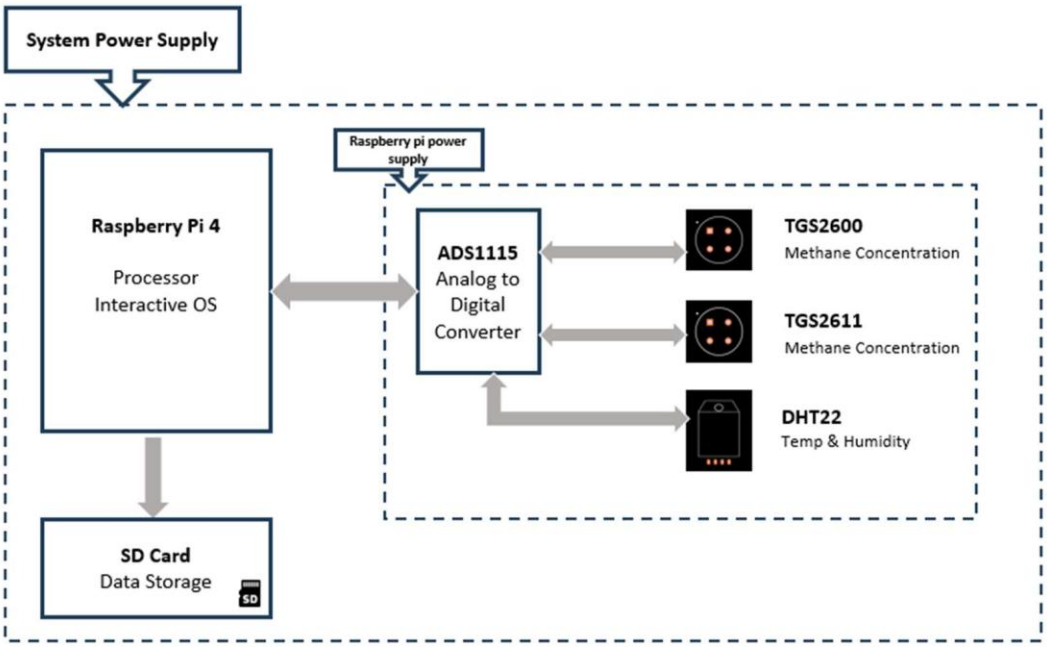


*รูปที่ 4: สถาปัตยกรรมระบบเซ็นเซอร์มีเทนต้นทุนต่ำร่วมกับ Raspberry Pi (Kiplimo et al., Atmosphere, 2024, Fig. 1; [10], [28])*

งานวิจัยของ Domènech-Gil et al. [10] ซึ่งพัฒนา eNose ต้นทุนต่ำสำหรับการติดตาม $CH_4$ ในบรรยากาศ โดยใช้เซ็นเซอร์ MOS หลายตัว (Figaro TGS2611) ควบคู่กับเซ็นเซอร์วัดอุณหภูมิ ความชื้น และความดัน (BME680) แล้วใช้แบบจำลอง Partial Least Squares Regression (PLSR) ชดเชยผลกระทบจากสภาพแวดล้อม ในห้องปฏิบัติการ ระบบให้ $R^2 > 0.9$ และ RMSE < 100 ppb ในช่วง 0–9 ppm $CH_4$ ส่วนในสภาพภาคสนามสามารถวัดได้ถึงระดับความเข้มข้นบรรยากาศ (ราว 2 ppm) โดยให้ค่าความคลาดเคลื่อน RMSE ต่ำสุดถึง 33 ppb และค่า $R^2$ สูงสุดถึง 0.91 [10] ผลลัพธ์นี้แสดงถึงความเป็นไปได้ของแนวทาง eNose+ML สำหรับการตรวจจับและประเมินปริมาณ $CH_4$ แต่ในการใช้งานจริงช่วงความเข้มข้นยังต่างจากนาข้าวที่มีความชื้นสูงและสภาพแวดล้อมซับซ้อน จึงไม่สามารถนำแบบจำลองมาใช้โดยตรง โดยข้อจำกัดที่ปรากฏซ้ำในวรรณกรรมคือ cross-sensitivity ต่อความชื้น อุณหภูมิ และก๊าซรบกวนอื่น เช่น Ahmad et al. [12] ทดลองศักยภาพของเซ็นเซอร์ MOS สำหรับ precision agriculture และเน้นว่าความไวต่อสารอินทรีย์ระเหยง่าย (VOC) และการเปลี่ยนแปลงของสภาพแวดล้อมยังเป็นข้อจำกัดหลักที่ต้องชดเชยด้วยแบบจำลองหลายตัวแปร งานสนับสนุนอื่น ๆ [25],[26]

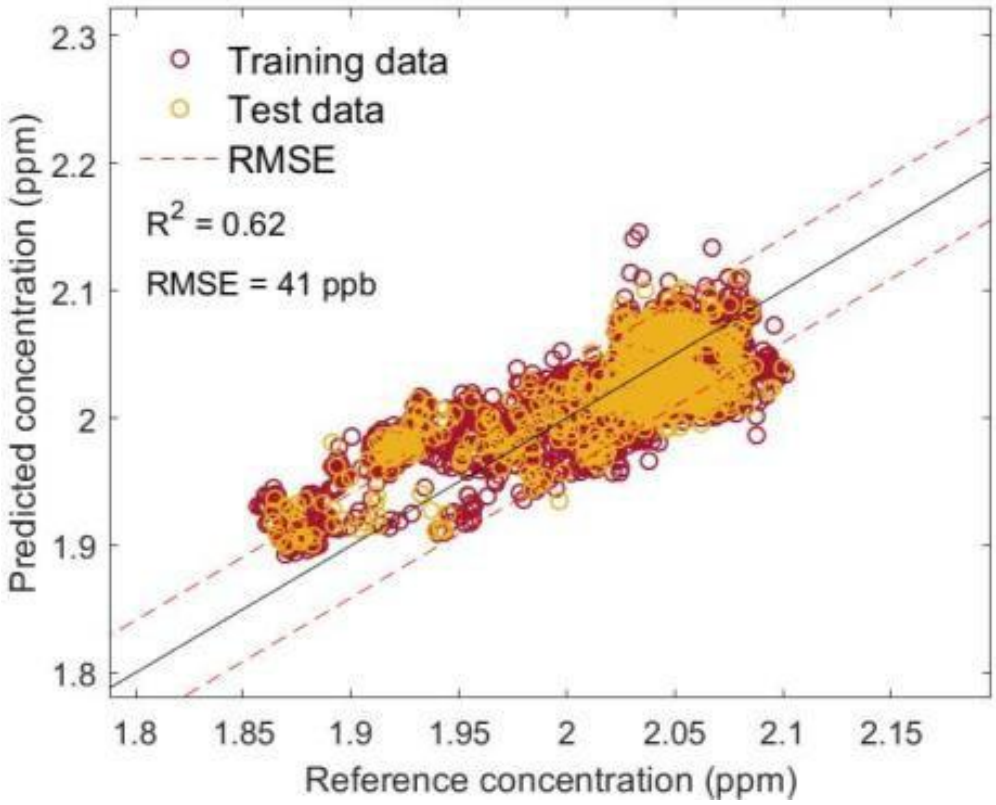


*รูปที่ 5: ผลสอบเทียบ eNose+PLSR กับค่าอ้างอิงในภาคสนาม [10]*

การชดเชย cross-sensitivity ของ MOS ด้วยเซ็นเซอร์สภาพแวดล้อม (T/H) ร่วมกับ ML เพื่อชดเชยผลของสภาพแวดล้อมต่างๆมีผลต่อความแม่นยำ [10], [12], [27] ยังไม่พบงานที่รวมทั้งสามองค์ประกอบ eNose แบบอาเรย์ MOS, ML regression ให้ค่า ppm ต่อเนื่อง และในบริบทของนาข้าว จึงมุ่งพัฒนาระบบ eNose ที่ชดเชยผลของสิ่งแวดล้อม และทำนายปริมาณ $CH_4$ ได้

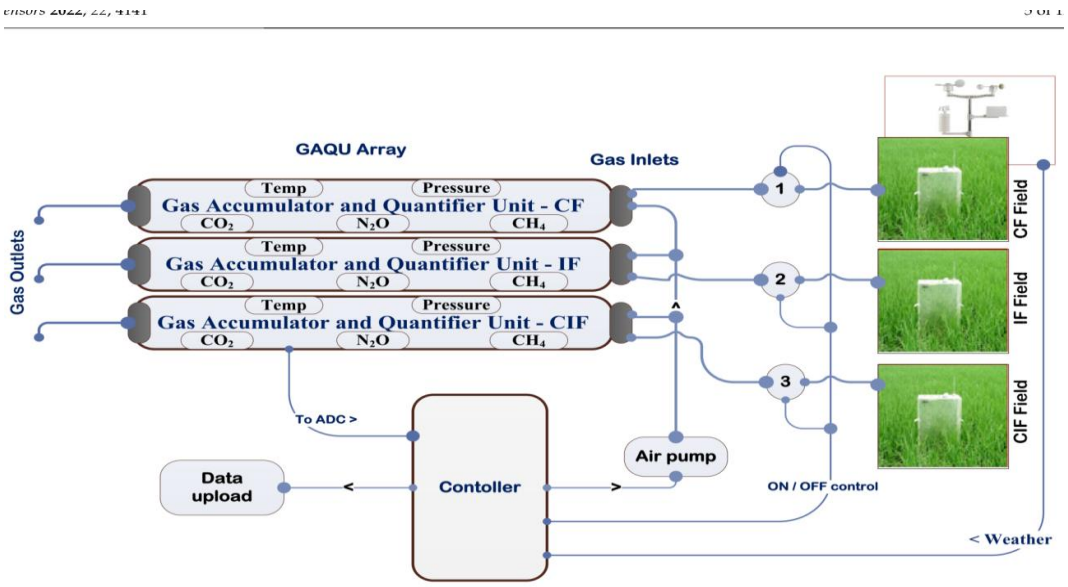

*รูปที่ 6: ระบบ chamber อัตโนมัติพร้อมเซ็นเซอร์สำหรับนาข้าว (ดัดแปลงจาก Rajasekar และ Selvi [5], Fig. 3)*

4.3. วัตถุประสงค์ของการศึกษา (Research Objectives)

- เพื่อพัฒนาเครื่องในการประเมินความเข้มข้นของก๊าซมีเทนในแปลงนาข้าว
- เพื่อสร้างแบบจำลองที่ประมาณความเข้มข้น $CH_4$ เป็น ppm

4.4. ขอบเขตของการศึกษา (Research scopes and limitations)

- ทดลองในห้องปฏิบัติการด้วยก๊าซมาตรฐาน $CH_4$ ช่วง 5–100 ppm ที่อุณหภูมิแวดล้อม 30, 40 และ 50 °C

4.5. ประโยชน์ที่คาดว่าจะได้รับ (Research Contribution)

- ได้เครื่องที่สามารถพกพาที่ติดตั้งและทำงานในแปลงนาได้
- ได้ข้อมูลและแบบจำลองที่นำไปใช้ในนาภายใต้ช่วงความเข้มข้นและอุณหภูมิที่ฝึกไว้

## 5. หลักการและทฤษฎีที่เกี่ยวข้อง

ระบบใช้จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) บน Raspberry Pi ประมาณความเข้มข้น $CH_4$ เป็นหน่วยส่วนในล้านส่วน (parts per million, ppm) โดยเทียบกับ Gas Chromatograph (GC) ฮาร์ดแวร์ประกอบด้วยเซ็นเซอร์โลหะออกไซด์ (metal oxide semiconductor, MOS) ชนิด Figaro TGS2612 สี่ช่อง (มีและไม่มีตัวกรองอย่างละสอง) เซ็นเซอร์สภาพแวดล้อม BME280 และตัวแปลงอนาล็อกเป็นดิจิทัล ADS1263 ลำดับการไหลถูกควบคุมด้วยวาล์วโซลินอยด์ ปั๊ม และฮีตเตอร์ เพื่อสร้างช่วง Baseline และ Measure จากนั้นสกัดลักษณะเด่น ได้แก่ การเปลี่ยนแปลงแรงดันสัมพัทธ์ ($\Delta$V) ความชัน อัตราส่วน และค่าเฉลี่ยอุณหภูมิ ความชื้น ความดัน แล้วส่งเข้าแบบจำลองถดถอยเชิงเส้น (Linear Regression) ที่ฝึกนอกเครื่องและโหลดขึ้น Raspberry Pi

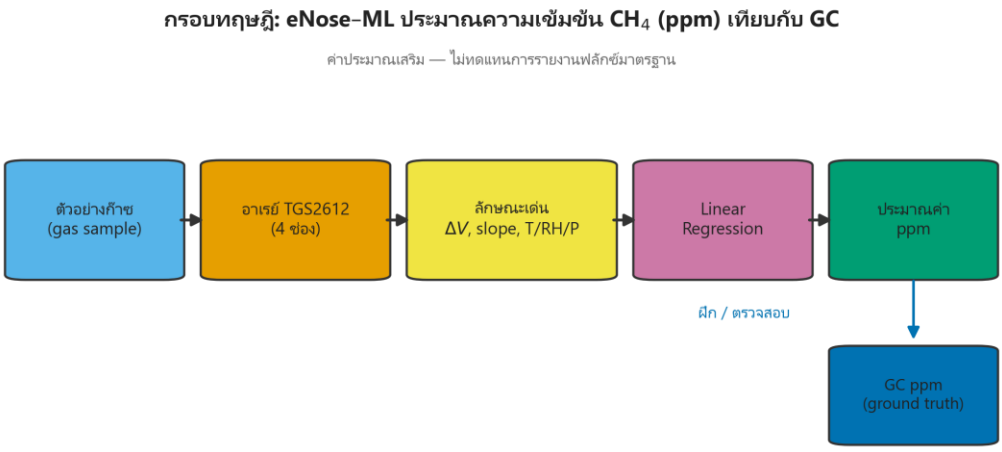


*รูปที่ 7 : กรอบทฤษฎีระบบ eNose–ML สำหรับประมาณความเข้มข้น $CH_4$ (ppm) และเปรียบเทียบกับ GC*

### 5.1. ก๊าซมีเทนในระบบนาข้าว

การปลูกข้าวแบบน้ำขังทำให้ดินใต้ผิวน้ำอยู่ในสภาวะไร้ออกซิเจน (anaerobic) จุลินทรีย์กลุ่มสร้างมีเทน (methanogens) จึงย่อยสลายอินทรียวัตถุและผลิต $CH_4$ ซึ่งปล่อยสู่บรรยากาศได้สามทางหลัก ได้แก่ การแพร่ผ่านผิวน้ำ การปล่อยเป็นฟอง (ebullition) และการลำเลียงผ่านระบบอากาศในต้นข้าว [4], [13] อัตราการผลิตและการปล่อยถูกกำกับด้วยการจัดการน้ำ พันธุ์ข้าว สภาพดินรอบราก (rhizosphere) ปริมาณคาร์บอนที่ใช้ได้ และค่า pH ของดิน [4], [17], [18], [19] ความเข้มข้น $CH_4$ เหนือผิวนามีพลวัตตามฤดูกาล ระยะเจริญเติบโต และช่วงเวลาในวัน การเก็บตัวอย่างห่างช่วงจึงอาจพลาดพลวัตรายวันหรือการเกิด ebullition [7], [13]

5.2. หลักการวัดด้วย static chamber และ GC

Static closed chamber คือการครอบห้องปิดบนผิวดินหรือผิวน้ำในช่วงสั้น ๆ เพื่อให้อากาศในหัวห้องสะสมก๊าซ หากอัตราการปล่อยคงที่พอสมควร ความเข้มข้น $CH_4$ จะเพิ่มขึ้นเกือบเชิงเส้นตามเวลา [6] การคำนวณฟลักซ์ใช้ความชันของความเข้มข้น คู่กับปริมาตรและพื้นที่ฐาน โดยต้องซีลขอบของ chamber และผสมอากาศในห้อง แล้วบันทึกอุณหภูมิ–ความดัน และเลือกช่วงถดถอยที่เหมาะสม [6] ในทางปฏิบัติ การครอบแบบมือร่วมกับ GC มักใช้เวลาประมาณ 20–30 นาทีต่อจุด จึงจำกัดจำนวนจุดต่อวันด้วยแรงงาน [7], [21]

ปริมาณที่ใช้ในการวัดมีสองค่า ได้แก่ ความเข้มข้น ซึ่งเป็นสัดส่วนของโมเลกุล $CH_4$ ในอากาศตัวอย่าง (ppm หรือ ppb) และฟลักซ์ ซึ่งเป็นอัตราการปล่อยมวลต่อหน่วยพื้นที่ต่อเวลา เช่น mg $CH_4$ $m^{-2}$ $h^{-1}$ ความสัมพันธ์ระหว่างสองปริมาณนี้เขียนได้ดังสมการ (5.1)–(5.3)

$$\rho_{CH_4} = c \cdot \frac{P\,M}{R\,T} \tag{5.1}$$

$$C(t) \approx C_0 + \frac{dC}{dt}\,t \tag{5.2}$$

$$F = \frac{dC}{dt} \cdot \frac{V}{A} \cdot \frac{P\,M}{R\,T} \tag{5.3}$$

เมื่อ

$\rho$_$CH_4$ คือ ความหนาแน่นมวลของ $CH_4$ (หน่วย: kg/m³)

c คือ ความเข้มข้นในหน่วยสัดส่วนโมล หรือค่าที่แปลงจาก ppm แล้ว (—)

P คือ ความดัน (หน่วย: Pa)

T คือ อุณหภูมิสัมบูรณ์ (หน่วย: K)

M คือ มวลโมเลกุลของ $CH_4$ (หน่วย: kg/mol)

R คือ ค่าคงที่แก๊ส (หน่วย: J/(mol·K))

C(t) คือ ความเข้มข้นในหัว chamber ตามเวลา

$C_0$ คือ ความเข้มข้นเริ่มต้นเมื่อครอบห้อง

dC/dt คือ ความชันความเข้มข้นต่อเวลาในช่วงที่เลือก

F คือ ฟลักซ์มวลของ $CH_4$ (หน่วย: เช่น mg·$m^{-2}$·$h^{-1}$)

V คือ ปริมาตรหัว chamber (หน่วย: m³)

A คือ พื้นที่ฐานที่ครอบ (หน่วย: m²)

Gas Chromatograph (GC) แยกส่วนประกอบของตัวอย่างก๊าซแล้ววัดสัญญาณของแต่ละชนิดตามลำดับเวลา จากนั้นแปลงเป็นความเข้มข้นโดยเทียบกับก๊าซมาตรฐาน [6] หลักการทำงานคือฉีด

ตัวอย่างเข้ากระแสก๊าซพา (carrier gas เช่น $N_2$, He หรือ Ar) ให้ไหลผ่าน packed column เช่น Haysep Q หรือ Molsieve ซึ่งทำให้ก๊าซต่างชนิดเคลื่อนที่ด้วยความเร็วต่างกัน [6] สำหรับ $CH_4$ มักใช้ flame ionization detector (FID) เมื่อก๊าซผ่านเปลวไฟจะเกิดอิเล็กตรอนอิสระและสร้างกระแสไฟฟ้าตามสัดส่วนปริมาณไฮโดรคาร์บอน แล้วใช้พื้นที่พีคเทียบเส้นสอบเทียบเพื่อได้ค่าความเข้มข้น [6], [7] ส่วน thermal conductivity detector (TCD) ในระบบวัดก๊าซเรือนกระจกหลายชนิดมักใช้วัด $CO_2$ [6]

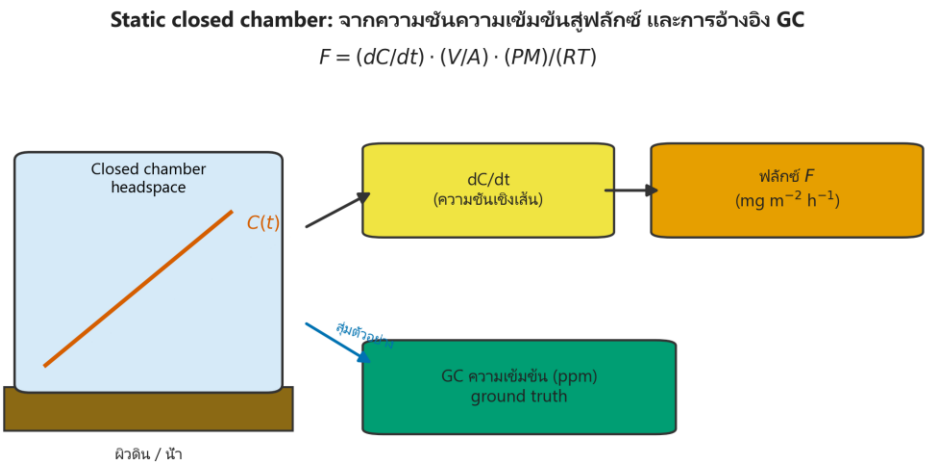


*รูปที่ 8: หลักการ static closed chamber ความชันความเข้มข้น ฟลักซ์ และการอ้างอิงด้วย GC*

## 5.3. หลักการจมูกอิเล็กทรอนิกส์และเซ็นเซอร์ MOS

จมูกอิเล็กทรอนิกส์ (electronic nose, eNose) จำลองแนวคิดการดมกลิ่นของจมูกคน โดยใช้เซ็นเซอร์ก๊าซหลายตัวร่วมกัน แทนที่จะพึ่งเซ็นเซอร์ตัวเดียวที่จำเพาะต่อก๊าซชนิดใดชนิดหนึ่ง เซ็นเซอร์แต่ละตัวมักตอบสนองต่อก๊าซได้หลายชนิดในระดับต่างกัน หรือมีความเลือกจำเพาะบางส่วน (partially selective) ดังนั้นเมื่อมีก๊าซเป้าหมาย เช่น $CH_4$ เข้ามา แต่ละช่องจะให้สัญญาณไม่เหมือนกัน เมื่อนำสัญญาณทุกช่องมารวมกันจะได้รูปแบบหลายมิติ หรือลายพิมพ์กลิ่น (smell print) จากนั้นใช้ซอฟต์แวร์วิเคราะห์รูปแบบและการเรียนรู้ของเครื่องเพื่อจำแนกชนิดก๊าซหรือประมาณความเข้มข้น [24]

เซ็นเซอร์ชนิดโลหะออกไซด์ (metal oxide semiconductor, MOS) ที่เลือกใช้ทำงานโดยให้ความร้อนชั้นวัสดุโลหะออกไซด์ เมื่อโมเลกุลก๊าซรีดิวซ์ เช่น $CH_4$ ทำปฏิกิริยาที่พื้นผิว ความต้านทานไฟฟ้าของชั้นวัสดุจะเปลี่ยนไป ระบบจึงอ่านค่าเป็นแรงดันผ่านวงจรแบ่งแรงดัน [12], [26]

$$V_{out} = V_c \frac{R_L}{R_S + R_L} \tag{5.4}$$

$$R_S = R_L\left(\frac{V_c}{V_{out}} - 1\right) \tag{5.5}$$

เมื่อ

V_out คือ แรงดันขาออกของวงจรแบ่งแรงดัน (V)

V_c คือ แรงดันจ่ายวงจร (V)

R_L คือ ความต้านทานโหลดคงที่ ($\Omega$)

R_S คือ ความต้านทานของชั้นเซ็นเซอร์ MOS ($\Omega$)

จุดเด่นของ MOS คือต้นทุนต่ำ ขนาดเล็ก และอ่านสัญญาณต่อเนื่องได้ ข้อจำกัดคือการตอบสนองมักไม่เป็นเส้นตรงตลอดช่วงความเข้มข้นกว้าง และสัญญาณยังเปลี่ยนตามความชื้น อุณหภูมิ ความดัน ก๊าซอื่นที่ปนอยู่ รวมทั้งสารอินทรีย์ระเหยง่าย (volatile organic compounds, VOC) [10], [12], [26] ข้อมูลผู้ผลิตตระกูล Figaro ยังแสดงว่าแรงดันขาออกขึ้นกับทั้งความเข้มข้นมีเทน อุณหภูมิ และความชื้น ดังนั้นช่วงความเข้มข้นต่ำมากอาจใช้ความสัมพันธ์เชิงเส้นได้เฉพาะช่วงแคบ [28] การจัดอาเรย์ให้มีทั้งช่องที่มีตัวกรองและไม่มีตัวกรองช่วยให้ลายพิมพ์สัญญาณหลากหลายขึ้น ซึ่งสอดคล้องกับแนวคิด eNose [24]

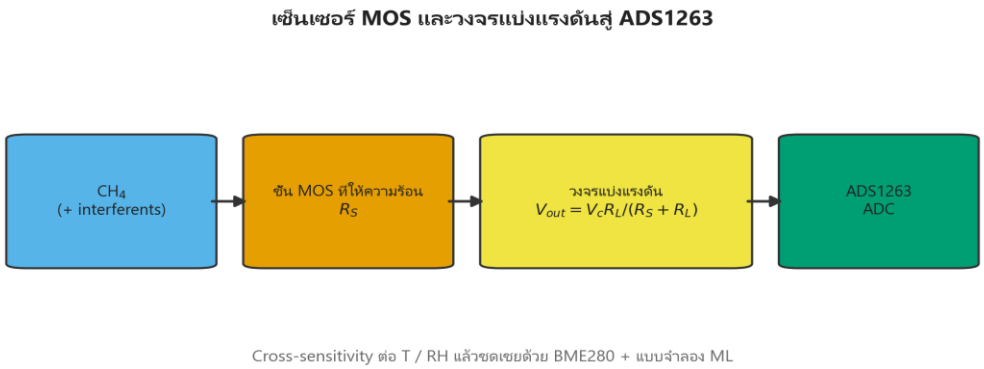


*รูปที่ 9: หลักการเซ็นเซอร์ MOS และวงจรแบ่งแรงดันสู่การอ่านด้วย ADS1263*

## 5.4. การไหลของก๊าซและการสกัดลักษณะเด่น

เพื่อให้เปรียบเทียบสัญญาณเซ็นเซอร์ระหว่างรอบวัดได้ ระบบต้องทำให้การไหลของอากาศและสภาวะก่อนวัดใกล้เคียงกันทุกครั้ง จึงควบคุมวาล์ว ปั๊ม และฮีตเตอร์ตามลำดับอัตโนมัติ แต่ละรอบแบ่งเป็นสองช่วงหลัก ได้แก่

ช่วงแรก Baseline คือช่วงอ้างอิงขณะไหลอากาศสะอาดหรือสภาวะอ้างอิง เพื่อดูว่าเซ็นเซอร์อยู่นิ่งที่ระดับใดก่อนเจอก๊าซตัวอย่าง และ ช่วงสอง Measure คือช่วงนำอากาศตัวอย่างเข้าห้องวัด เพื่อดูว่า

สัญญาณเปลี่ยนไปอย่างไรเมื่อมี $CH_4$ หรือก๊าซที่เกี่ยวข้อง การวัดแบบนี้ช่วยให้ใช้การเปลี่ยนแปลงของสัญญาณเทียบกับเบสไลน์ แทนการใช้แรงดันดิบเพียงอย่างเดียว จึงลดผลจากการเลื่อนเบสไลน์ระหว่างวันหรือระหว่างเงื่อนไขอุณหภูมิ [12], [26], [28]

อุณหภูมิห้องทดสอบถูกควบคุมด้วยฮีตเตอร์ เพราะอุณหภูมิมีผลทั้งต่อปฏิกิริยาที่พื้นผิวเซ็นเซอร์และต่อความชื้นในอากาศตัวอย่าง [12], [26], [28] สัญญาณที่อ่านจาก ADS1263 มีสัญญาณรบกวนความถี่สูง จึงต้องผ่านตัวกรองความถี่ต่ำ (low-pass filter)และค่าเฉลี่ยเคลื่อนที่(smoothing average) ก่อนนำไปหาค่าต่ำสุด ค่าสูงสุด และค่าเฉลี่ยในช่วงวิเคราะห์ หน้าต่างเวลาของ Baseline และ Measure ต้องตรงกับที่ใช้ตอนฝึกโมเดล หากเปลี่ยนหน้าต่างโดยไม่ฝึกใหม่ การทำนายจะคลาดเคลื่อน

ให้ V_bl,i เป็นค่าเฉลี่ยแรงดันของช่องเซ็นเซอร์ที่ i ในช่วง Baseline และให้ V_min,i กับ V_max,i เป็นค่าต่ำสุดและค่าสูงสุดในช่วง Measure ลักษณะเด่นหลักคำนวณจากผลต่างของสัญญาณในช่วง Measure เทียบกับเบสไลน์ โดยเลือกใช้ค่าสูงสุดหรือค่าต่ำสุดในช่วง Measure เป็น V_ext,i ตามทิศทางสัญญาณ ดังสมการ (5.6)–(5.8)

$$\Delta V_i = V_{ext,i} - V_{bl,i} \tag{5.6}$$

$$slope_i = \frac{V_{max,i} - V_{min,i}}{t_{max,i} - t_{min,i}} \tag{5.7}$$

$$ratio_i = \frac{V_{max,i} - V_{bl,i}}{V_{bl,i}} \tag{5.8}$$

เมื่อ

V_bl,i คือ ค่าเฉลี่ยแรงดันของช่องเซ็นเซอร์ที่ i ในช่วง Baseline (หน่วย: V)

V_ext,i คือ ค่าสูงสุดหรือค่าต่ำสุดในช่วง Measure ตามทิศทางสัญญาณของช่อง i (หน่วย: V)

ΔV_i คือ ผลต่างแรงดันสัมพัทธ์ของช่อง i (หน่วย: V)

slope_i คือ ความชันสัญญาณในช่วง Measure จาก (V_max,i − V_min,i)/(t_max,i − t_min,i) (หน่วย: V/s)

ratio_i คือ อัตราส่วนการตอบสนองแบบนอร์มอลไลซ์ (V_max,i − V_bl,i)/V_bl,i (−)

ในระบบจริง แต่ละช่องอาจตอบสนองคนละทิศทาง บางช่องสัญญาณลงจากเบสไลน์จึงใช้ ΔV = V_min,i − V_bl,i บางช่องสัญญาณขึ้นจึงใช้ V_max,i − V_bl,i ส่วน dV_max,i = V_max,i − V_bl,i ใช้กับทุกช่อง และ ratio_i ในสมการ (5.8) นอร์มอลไลซ์ dV_max,i ด้วยค่า Baseline ระบบยังใช้ค่าเฉลี่ยอุณหภูมิและความชื้นในช่วง Baseline และ Measure และค่าเฉลี่ยความดันในช่วง Measure จาก BME280 เป็นตัวแปรร่วม

## 5.5. การเรียนรู้ของเครื่องสำหรับการประมาณความเข้มข้น

การเรียนรู้ของเครื่องใช้สร้างความสัมพันธ์ระหว่างสัญญาณที่ระบบวัดได้กับความเข้มข้น $CH_4$ อ้างอิงจาก GC ข้อมูลนำเข้าคือเวกเตอร์จากลักษณะเด่นจากแต่ละเซ็นเซอร์ก๊าซและ BME280 ตามหัวข้อ 5.4 ส่วนผลลัพธ์คือค่าความเข้มข้นต่อเนื่องในหน่วย ppm งานลักษณะนี้เรียกว่าการถดถอย (regression) ซึ่งต่างจากการจำแนกประเภทที่ให้คำตอบเป็นกลุ่ม เช่น มีหรือไม่มีมีเทน แบบจำลองหลักที่เลือกใช้คือสมการการถดถอยเชิงเส้น (Linear Regression)

หลักการฝึกเป็นการเรียนรู้แบบมีผู้สอน (supervised learning) โดยแต่ละรอบวัดประกอบด้วยคู่ข้อมูล (x, y) เมื่อ x คือเวกเตอร์ลักษณะเด่น และ y คือความเข้มข้นอ้างอิงจาก GC ก่อนฝึกจะเลือกเฉพาะลักษณะเด่นที่ใช้กับโมเดล จากนั้น Linear Regression จะหาค่าสัมประสิทธิ์ที่ทำให้ผลรวมกำลังสองของความคลาดเคลื่อนระหว่างค่าทำนายกับค่าอ้างอิงต่ำที่สุด หรือหลักการ least squares ตัวแปร x มีหน่วยต่างกันจึงต้องปรับมาตราส่วนก่อนเข้าสมการ ดังอธิบายในหัวข้อ 5.5.1

$$\hat{y} = \beta_0 + \sum_j \beta_j \, x_j \tag{5.9}$$

เมื่อ

$\hat{y}$ คือ ความเข้มข้นที่แบบจำลองประมาณได้ (หน่วย: ppm)

$\beta_0$ คือ ค่าคงที่ของสมการ

$\beta_j$ คือ สัมประสิทธิ์หรือน้ำหนักของลักษณะเด่นที่ j

$x_j$ คือ ค่าลักษณะเด่นแต่ละตัว (หน่วยตามชนิดตัวแปร)

Linear Regression มีข้อดีคือตีความสัมประสิทธิ์ได้ คำนวณรวดเร็ว และเหมาะกับคอมพิวเตอร์ขนาดเล็ก วิธีนี้ตั้งอยู่บนสมมติฐานว่าความสัมพันธ์ระหว่างลักษณะเด่นกับความเข้มข้นอธิบายได้ด้วยผลรวมเชิงเส้น หากตัวแปรจำนวนมากมีความสัมพันธ์กัน งาน eNose สำหรับ $CH_4$ บางชุดใช้ Partial Least Squares Regression (PLSR) เพื่อจัดการสหสัมพันธ์ระหว่างตัวแปร [10] ขณะที่การสอบเทียบเซ็นเซอร์ Figaro แสดงว่าการใส่อุณหภูมิและความชื้นช่วยลดความคลาดเคลื่อนในบางช่วงความเข้มข้น [27], [28] จึงเลือก Linear Regression ภายในช่วงฝึกประมาณ 5–100 ppm และตรวจสอบผลกับ GC โดยค่าที่ได้เป็นค่าประมาณจากแบบจำลองเทียบกับผลวัดจากเครื่องมืออ้างอิง หากนำไปใช้นอกช่วงความเข้มข้นหรือสภาวะที่ฝึก ต้องเก็บข้อมูลอ้างอิงและฝึกตรวจสอบโมเดลใหม่

### 5.5.1 การปรับมาตราส่วนด้วย StandardScaler

StandardScaler คือการแปลงค่าลักษณะเด่นแต่ละตัวให้อยู่สเกลเดียวกัน
โดยหักค่าเฉลี่ยแล้วหารด้วยส่วนเบี่ยงเบนมาตรฐาน
ผลลัพธ์มีค่าเฉลี่ยเป็นศูนย์และส่วนเบี่ยงเบนมาตรฐานเป็นหนึ่ง จำเป็นเพราะ dVmax

มีหน่วยเป็นโวลต์ ขณะที่อุณหภูมิจาก BME280 มีหน่วยเป็นองศาเซลเซียส หากป้อนค่าดิบเข้า Linear Regression โดยตรง สัมประสิทธิ์จะใหญ่ตามตัวแปรที่มีค่ามาก ไม่สะท้อนความสำคัญที่แท้จริง [31] การแปลงเขียนได้ดังสมการ (5.10)

$$z_j = (x_j - \mu_j) / \sigma_j \quad (5.10)$$

เมื่อ

$z_j$ คือ ค่าที่ปรับมาตราส่วนแล้ว

$x_j$ คือ ค่าลักษณะเด่นดิบ

$\mu_j$ คือ ค่าเฉลี่ยของลักษณะเด่นที่ j ในชุดฝึก

$\sigma_j$ คือ ส่วนเบี่ยงเบนมาตรฐานของลักษณะเด่นที่ j ในชุดฝึก

ค่า $\mu_j$ และ $\sigma_j$ ต้องคำนวณจากชุดฝึกเท่านั้น แล้วนำค่าเดิมไปใช้กับชุดทดสอบ หากคำนวณจากข้อมูลทั้งหมดรวมชุดทดสอบ จะเกิด data leakage คือข้อมูลชุดทดสอบรั่วเข้าขั้นตอนฝึก ทำให้ผลที่รายงานดีเกินจริง [31] จึงแบ่งข้อมูลเป็นชุดฝึกกับชุดทดสอบก่อนปรับมาตราส่วน ตามหัวข้อ 5.5.2

### 5.5.2 การตรวจสอบข้ามด้วย GroupKFold

Cross-validation คือการประเมินแบบจำลองบนข้อมูลที่ไม่ได้ใช้ฝึก ไม่ใช่ดูเฉพาะชุดฝึก เพราะแบบจำลองที่จำชุดฝึกได้ดีอาจคลาดเคลื่อนเมื่อเจอข้อมูลใหม่ เรียกว่า overfitting [31] วิธีทำคือแบ่งข้อมูลเป็น k ส่วน เรียกว่า fold แล้ววนซ้ำ k ครั้ง แต่ละครั้งใช้หนึ่ง fold เป็นชุดทดสอบ และ fold ที่เหลือเป็นชุดฝึก จากนั้นเฉลี่ยผลจากทุกครั้ง จึงเสถียรกว่าการแบ่งครั้งเดียว [30]

GroupKFold คือ cross-validation ที่บังคับให้ข้อมูลกลุ่มเดียวกันไม่แยกอยู่ทั้งชุดฝึกและชุดทดสอบในรอบเดียวกัน ในงานนี้หลายรอบวัดอยู่ภายใต้ความเข้มข้นและอุณหภูมิเดียวกัน หากสุ่มแบ่งโดยไม่ดูกลุ่ม ชุดฝึกกับชุดทดสอบอาจมีรอบจากสภาวะเดียวกันปนกัน ผลประเมินจะดูดีเกินจริง [29] จึงกำหนดกลุ่มตามระดับความเข้มข้น $CH_4$ อุณหภูมิ และรอบซ้ำ และใช้ k = 5 เพื่อให้ผลสะท้อนการทำนายในสภาวะที่แบบจำลองยังไม่เคยเห็น [29], [30]

### 5.5.3 ตัวชี้วัดความคลาดเคลื่อน

หลังฝึกแบบจำลองแล้ว ประเมินความใกล้เคียงระหว่างค่าที่ทำนายกับค่าจาก GC ด้วยตัวชี้วัดสามตัว ได้แก่ ค่ารากที่สองของความคลาดเคลื่อนกำลังสองเฉลี่ย (root mean square error, RMSE) ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (mean absolute error, MAE) ซึ่งมีหน่วยเดียวกับ

ppm และสัมประสิทธิ์การตัดสินใจ ($R^2$)

ซึ่งสะท้อนว่าแบบจำลองอธิบายความแปรปรวนของค่าอ้างอิงได้มากน้อยเพียงใด

$$RMSE = \sqrt{\frac{1}{n}\sum_{k=1}^{n}(y_k - \hat{y}_k)^2} \tag{5.11}$$

$$MAE = \frac{1}{n}\sum_{k=1}^{n}|y_k - \hat{y}_k| \tag{5.12}$$

$$R^2 = 1 - \frac{\sum_k (y_k - \hat{y}_k)^2}{\sum_k (y_k - \bar{y})^2} \tag{5.13}$$

เมื่อ

y_k คือ ค่าอ้างอิงจาก GC ของตัวอย่างที่ k (หน่วย: ppm)

$\hat{y}$_k คือ ค่าที่แบบจำลองทำนาย (หน่วย: ppm)

$\bar{y}$ คือ ค่าเฉลี่ยของ y_k (หน่วย: ppm)

n คือ จำนวนตัวอย่างในชุดประเมิน

RMSE และ MAE ยิ่งต่ำยิ่งดี ส่วน $R^2$ โดยทั่วไปอยู่ในช่วงประมาณ 0–1 และยิ่งใกล้ 1 ยิ่งสอดคล้องกับข้อมูลอ้างอิง ตัวชี้วัดเหล่านี้คำนวณบนชุดทดสอบของแต่ละ fold ตามหัวข้อ 5.5.2 ภายใต้ช่วงความเข้มข้นและสภาวะที่กำหนด [6], [7]

## 6. วิธีการดำเนินงานวิจัย

### 6.1. การทดลองและเก็บข้อมูล

เครื่องประกอบด้วย Raspberry Pi เป็นหน่วยควบคุม เซ็นเซอร์ Figaro TGS2612 สี่ช่อง (ss1–ss4; มีและไม่มีตัวกรองอย่างละสอง) เซ็นเซอร์สภาพแวดล้อม BME280 ตัวแปลง ADS1263 และชุดวาล์ว ปั๊มพัดลม ฮีตเตอร์ ทดสอบที่ความเข้มข้นในช่วง 5–100 ppm และอุณหภูมิ 30, 40 และ 50 °C ตามหัวข้อ 4.4 ขั้นตอนต่อหนึ่งรอบมีดังนี้

1. อุ่นเซ็นเซอร์ด้วยฮีตเตอร์ประมาณ 30 นาที โดยยังไม่บันทึกสัญญาณ เพื่อให้สภาวะความร้อนคงที่
2. ช่วง Baseline บันทึกสัญญาณขณะไหลอากาศอ้างอิง 300 วินาที ใช้ช่วงวิเคราะห์วินาทีที่ 250–300 เป็นค่าเฉลี่ยแรงดันอ้างอิง V_bl
3. ช่วง Measure นำก๊าซตัวอย่างเข้าห้องวัด 60 วินาที ใช้ช่วง 305–365 วินาที และเก็บ vial ส่ง GC เพื่อได้ค่า ppm อ้างอิง
4. ช่วง Recovery ล้างห้องวัดประมาณ 180 วินาที แล้วหยุดบันทึก จะได้ไฟล์ adc1263_*.csv และ bme280_*.csv ที่เป็นค่าสัญญาณจากเซ็นเซอร์และค่าสัญญาณสภาพแวดล้อม

### 6.2. การสร้างและประเมินแบบจำลอง

แบบจำลองหลักคือ Linear Regression ตามสมการ (5.9) ฝึกนอกเครื่องแล้วโหลดขึ้น Raspberry Pi เพื่อทำนายหลังจบแต่ละรอบ [31] ขั้นตอนมีดังนี้

1. สกัดลักษณะเด่น dVmax ของช่อง ss3 และ ss4 ร่วมกับอุณหภูมิเฉลี่ยช่วง Baseline และ Measure จาก BME280 ตัวแปรตามคือความเข้มข้น $CH_4$ จาก GC
2. แบ่งข้อมูลด้วย GroupKFold จำนวน 5 กลุ่ม โดยจัดกลุ่มตามความเข้มข้น × อุณหภูมิ × รอบซ้ำ เพื่อไม่ให้รอบจากสภาวะเดียวกันรั่วข้ามชุดฝึกกับชุดทดสอบ
3. ปรับมาตราส่วนด้วย StandardScaler ที่คำนวณจากชุดฝึกเท่านั้น แล้วฝึก Linear Regression ด้วยหลัก least squares ตามสมการ (5.9)
4. ประเมินด้วย RMSE, MAE และ $R^2$ ตามสมการ (5.11)–(5.13) แล้วบันทึกแบบจำลองเป็นไฟล์ joblib และโหลดขึ้น Raspberry Pi

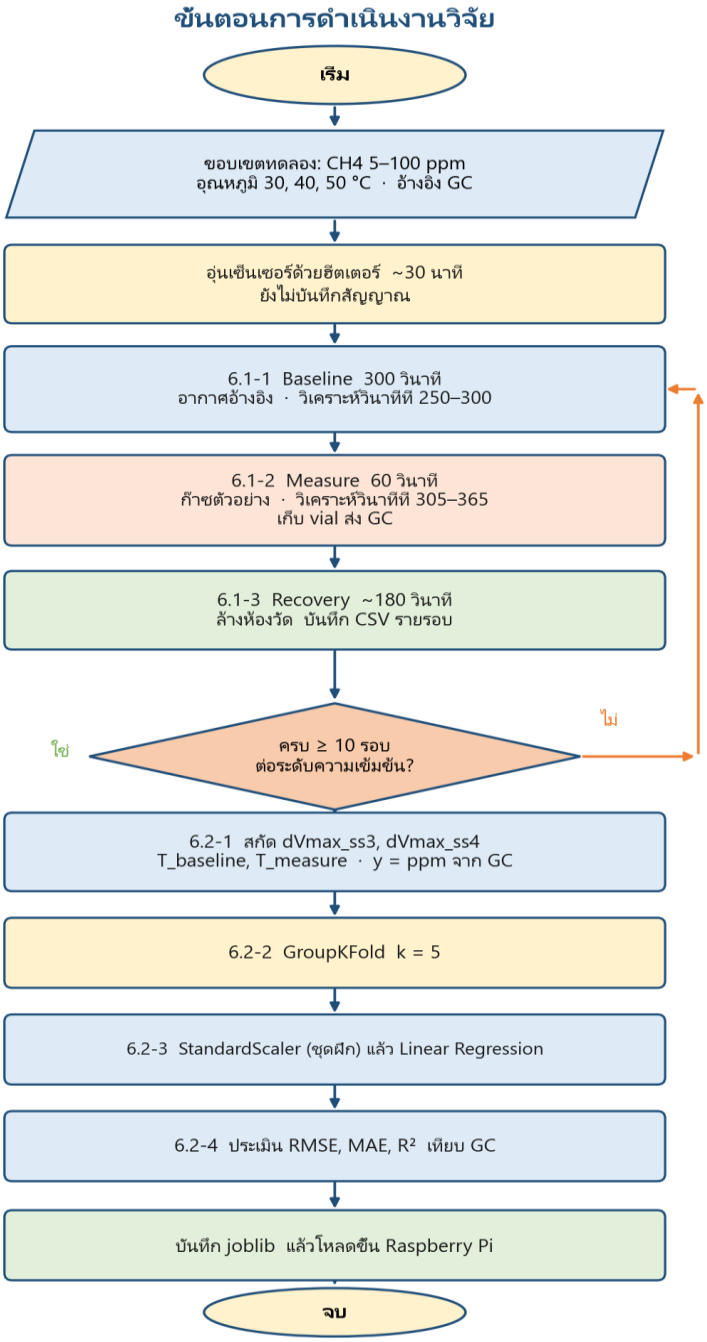


*รูปที่ 6.1 ขั้นตอนการดำเนินงานวิจัยของระบบ eNose–ML*

7. สถานที่ในการดำเนินโครงการ (Location)

การทดลองในห้องปฏิบัติการดำเนินการที่ภาควิชาวิศวกรรมเครื่องกล คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่

การวิเคราะห์ก๊าซอ้างอิงด้วยแก๊สโครมาโทกราฟใช้เครื่องมือของหน่วยงานที่ให้บริการในมหาวิทยาลัย

8. แผนการดำเนินงาน (Project timeline)

การดำเนินโครงการนี้มีรายละเอียดของการดำเนินงานดังตารางที่ 8.1 ระยะเวลาดำเนินโครงการ 2 ปี

| แผนงาน | ปีที่ 1 | | | | ปีที่ 2 | | | |
|---|---|---|---|---|---|---|---|---|
| | 1-3 | 4-6 | 7-9 | 10-12 | 1-3 | 4-6 | 7-9 | 10-12 |
| ศึกษาทบทวนวรรณกรรมที่เกี่ยวข้อง | | | | | | | | |
| ออกแบบและปรับระบบเครื่อง eNose | | | | | | | | |
| เตรียมก๊าซสอบเทียบและเก็บข้อมูลในห้องปฏิบัติการ | | | | | | | | |
| สร้างและประเมินแบบจำลองถดถอย | | | | | | | | |
| วิเคราะห์ผลและเขียนวิทยานิพนธ์ | | | | | | | | |

*ตารางที่ 8.1 ขั้นตอนการดำเนินงาน*

9. งบประมาณ (Budget)

งบประมาณส่วนที่ต้องจัดซื้อเพิ่มเติมอยู่ในกรอบไม่เกิน 15,000 บาท สำหรับชุดผสมแก๊สสอบเทียบ รายละเอียดดังตารางที่ 9.1

| รายการ | จำนวน | ราคาต่อหน่วย (บาท) | ราคารวม (บาท) |
|---|---|---|---|
| เครื่อง eNose | 1 เครื่อง | 55000 | 55000 |
| การตรวจ GC | 10 ครั้ง | 1000 | 10000 |
| ชุดผสมแก๊สสอบเทียบ | 1 ชุด | 50000 | 50000 |
| **รวม** | | | 115000 |

*ตารางที่ 9.1 รายการงบประมาณของโครงการ*

10. ระยะเวลาการดำเนินโครงการ (Project duration)

**เอกสารอ้างอิง (References)**


[1] C. Sowcharoensuk, "Industry Outlook 2026-2028: Rice Industry," Krungsri Research, 2026. [Online]. Available: https://www.krungsri.com/th/research/industry/industry-outlook/agriculture/rice/io/io-rice-2026-2028

[2] T. Nation, "Thai farm incomes face pressure from global rice market shifts," *The Nation*, 2026.

[3] Thairath, "Thai Rice Exports in 2025 Surpass Targets Efforts Accelerate in 2026 to Maintain and Expand Markets," *Thairath*, 2026.

[4] H. Nguyen et al., "Carbon Footprint Reduction from Closing Rice Yield Gaps," in *Carbon Footprint of Rice Production*, 2023, pp. 149–176.

[5] P. Rajasekar and J. A. V. Selvi, "Sensing and Analysis of Greenhouse Gas Emissions from Rice Fields to the Near Field Atmosphere," *Sensors*, vol. 22, no. 11, p. 4141, 2022.

[6] M. Zaman et al., "Methodology for measuring greenhouse gas emissions from agricultural soils using non-isotopic techniques," in *Measuring Emission of Agricultural Greenhouse Gases and Developing Mitigation Options Using Nuclear and Related Techniques*, Springer, 2021, pp. 11–108.

[7] N. J. Mumu et al., "Methodological progress in the measurement of agricultural greenhouse gases," *Carbon Management*, vol. 15, no. 1, p. 2366527, 2024.

[8] L. Tyagi et al., "Environmental impacts and recent advancements in the sensing of methane: a review," *Environ. Technol. Rev.*, vol. 14, no. 1, pp. 191–212, 2025.

[9] M. S. Borhan and M. M. Khanaum, "Sensors and methods for measuring greenhouse gas emissions from different components of livestock production facilities," *J. Geosci. Environ. Prot.*, vol. 10, no. 12, pp. 242–272, 2022.

[10] G. Domènech-Gil et al., "Electronic nose for improved environmental methane monitoring," *Environ. Sci. Technol.*, vol. 58, no. 1, pp. 352–361, 2023.

[11] S. Baruah and D. H. Mazumder, "A Review on Application of Machine Learning Techniques Coupled With E-Nose in Healthcare Agriculture and Allied Domains," *IEEE Access*, 2025.

[12] A. Ahmad et al., "The Promise of Low-Cost Metal-Oxide Semiconductor Gas Sensors for Precision Agriculture," *Adv. Sensor Res.*, 2026.

[13] H. Zhou et al., "Paddy rice methane emissions, controlling factors, and mitigation potentials across Monsoon Asia," Sci. Total Environ., vol. 935, p. 173441, 2024, doi: 10.1016/j.scitotenv.2024.173441.

[14] T. D. Xuan, T. T. N. Minh, R. Rayee, N. Dong, and N. X. Chien, "Advances in mitigating methane emissions from rice cultivation: past, present, and future strategies," Environ. Sci. Pollut. Res., 2025, doi: 10.1007/s11356-025-36776-8.

[15] A. Rafy, M. Hannan, M. Mohammed, and N. Khan, "Meta-Analysis of Alternate Wetting and Drying (AWD) Irrigation Effects on Methane and Nitrous Oxide Emissions Across Different Climates and Soil Types," Eur. J. Ecol. Biol. Agric., vol. 2, no. 5, pp. 181-200, 2025, doi: 10.59324/ejeba.2025.2(5).13.

[16] S. S. Anapalli, S. R. Pinnamaneni, K. N. Reddy, P. Wagle, and A. J. Ashworth, "Eddy covariance assessment of alternate wetting and drying floodwater management on rice methane emissions," Heliyon, vol. 9, no. 4, p. e14696, 2023, doi: 10.1016/j.heliyon.2023.e14696.

[17] S. Guan, Z. Qi, S. Li, S. Du, and D. Xu, "Effects of rice root development and rhizosphere soil on methane emission in paddy fields," Plants, vol. 13, no. 22, p. 3223, 2024, doi: 10.3390/plants13223223.

[18] D. Yusong et al., "Methane emissions from rice paddies are regulated by carbon availability and soil pH along a mean annual temperature gradient," Sci. Rep., vol. 16, p. 14129, 2026, doi: 10.1038/s41598-026-43940-8.

[19] T. Yang, M. Wang, X. Wang, C. Xu, F. Fang, and F. Li, "Product type, rice variety, and agronomic measures determined the efficacy of enhanced-efficiency nitrogen fertilizer on the CH4 emission and rice yields in paddy fields: A meta-analysis," Agronomy, vol. 12, no. 10, p. 2240, 2022, doi: 10.3390/agronomy12102240.

[20] Q. Hu et al., "Global methane emissions from rice paddies: CH4MOD model development and application," iScience, vol. 27, no. 11, p. 111237, 2024, doi: 10.1016/j.isci.2024.111237.

[21] T. B. T. Vo et al., "Measurement approaches for greenhouse gas emissions from rice II: advanced technology for accelerating throughput," Front. Agron., vol. 7, p. 1693620, 2026, doi: 10.3389/fagro.2025.1693620.

[22] Y. Xu, A. Yazdinejad, H. Wang, and J. D. Kong, "From detection to decision: A systematic literature review of AI and machine learning evolution in methane modelling," SSRN, 2025, doi: 10.2139/ssrn.5218753.

[23] Q. Zhang et al., "Machine learning-driven method for in-situ high-frequency CH4 measurement in paddy fields based on water-soil-air factors," J. Environ. Manage., vol. 393, p. 127132, 2025, doi: 10.1016/j.jenvman.2025.127132.

[24] Z. Ye, Y. Liu, and Q. Li, "Recent progress in smart electronic nose technologies enabled with machine learning methods," Sensors, vol. 21, no. 22, p. 7620, 2021, doi: 10.3390/s21227620.

[25] J. Yin et al., "Rapid identification method for CH4/CO/CH4-CO gas mixtures based on electronic nose," Sensors, vol. 23, no. 6, p. 2975, 2023, doi: 10.3390/s23062975.

[26] L. Fu, S. You, G. Li, X. Li, and Z. Fan, "Application of semiconductor metal oxide in chemiresistive methane gas sensor: Recent developments and future perspectives," Molecules, vol. 28, no. 18, p. 6710, 2023, doi: 10.3390/molecules28186710.

[27] B. Andrews, A. Chakrabarti, M. Dauphin, and A. Speck, "Application of machine learning for calibrating gas sensors for methane emissions monitoring," Sensors, vol. 23, no. 24, p. 9898, 2023, doi: 10.3390/s23249898.

[28] H. L. Mitchell, S. J. Cox, and H. G. Lewis, "Calibration of a low-cost methane sensor using machine learning," Sensors, vol. 24, no. 4, p. 1066, 2024, doi: 10.3390/s24041066.

[29] J. W. Creswell, *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*, 3rd ed. SAGE Publications, 2009.

[30] B. Madsen, *Statistics for Non-Statisticians*. Springer-Verlag Berlin Heidelberg, 2011. DOI: 10.1007/978-3-642-17656-2

[31] M. P. Deisenroth, A. A. Faisal, and C. S. Ong, *Mathematics for Machine Learning*. Cambridge University Press, 2020.